

BỘ GIÁO DỤC VÀ ĐÀO TẠO
TRƯỜNG ĐẠI HỌC MỞ THÀNH PHỐ HỒ CHÍ MINH

BÁO CÁO TỔNG KẾT

ĐỀ TÀI NGHIÊN CỨU KHOA HỌC SINH VIÊN

ỨNG DỤNG PHƯƠNG PHÁP HỌC MÁY XÂY DỰNG
MÔ HÌNH NHẬN DẠNG TIN TỨC GIẢ MẠO

MÃ SỐ ĐỀ TÀI: 246

TP Hồ Chí Minh, 03/2025

BỘ GIÁO DỤC VÀ ĐÀO TẠO
TRƯỜNG ĐẠI HỌC MỞ THÀNH PHỐ HỒ CHÍ MINH

BÁO CÁO TỔNG KẾT

ĐỀ TÀI NGHIÊN CỨU KHOA HỌC SINH VIÊN

ỨNG DỤNG PHƯƠNG PHÁP HỌC MÁY XÂY DỰNG MÔ HÌNH NHẬN DẠNG TIN TỨC GIẢ MẠO

MÃ SỐ ĐỀ TÀI: 246

Chủ nhiệm đề tài: VÕ PHƯƠNG LINH

Khoa: CÔNG NGHỆ THÔNG TIN

Các thành viên: LÊ KIỀU CHINH
NGUYỄN QUỐC KHANG

Người hướng dẫn: Th.S HỒ HƯỚNG THIÊN

TP Hồ Chí Minh, 03/2025

THÔNG TIN KẾT QUẢ NGHIÊN CỨU CỦA ĐỀ TÀI

1. Thông tin chung:

- Tên đề tài: Ứng Dụng Phương Pháp Học Máy Xây Dựng Nhận Dạng Tin Tức Giả Mạo
- Mã số đề tài: 246
- Sinh viên chủ nhiệm đề tài: Võ Phương Linh
- Khoa: Công Nghệ Thông Tin
- Mã số sinh viên: 2154050159
- Giảng viên hướng dẫn: ThS. Hồ Hương Thiên

2. Mục tiêu đề tài:

Mục tiêu của đề tài là ứng dụng các phương pháp học máy để xây dựng mô hình nhận dạng tin tức giả mạo, qua đó phân loại tin tức một cách chính xác và hiệu quả. Nghiên cứu tập trung vào việc khai thác các đặc trưng ngôn ngữ, áp dụng các mô hình học sâu nhằm đánh giá khả năng phát hiện tin giả. Đồng thời, đề tài hướng đến việc phân tích đặc điểm ngôn ngữ của tin tức, góp phần cung cấp cơ sở khoa học cho các nghiên cứu về xử lý ngôn ngữ tự nhiên (NLP) và ứng dụng trong thực tiễn.

3. Tính mới và sáng tạo:

Nghiên cứu này sáng tạo ở việc kết hợp nhiều mô hình học sâu như BERT, LSTM và CNN để nhận diện tin giả, đồng thời so sánh hiệu suất giữa các phương pháp. Ngoài ra, việc sử dụng phương pháp TF-IDF và Word Cloud giúp phân tích đặc điểm ngôn ngữ của tin tức giả mạo, cung cấp góc nhìn sâu sắc hơn về cách tin giả được xây dựng. Nghiên cứu không chỉ tập trung vào mô hình hóa mà còn mở ra hướng tiếp cận liên ngành giữa NLP và khoa học hành vi, tạo tiền đề cho các nghiên cứu cải tiến trong tương lai.

4. Kết quả nghiên cứu:

Nghiên cứu đã thành công trong việc xây dựng và đánh giá các mô hình học sâu để nhận diện tin giả. Kết quả thực nghiệm cho thấy các mô hình này đạt hiệu suất phân loại đáng kể, phản ánh rõ sự khác biệt ngôn ngữ giữa tin thật và tin giả thông qua các phương pháp phân tích như TF-IDF và Word Cloud. Những phát hiện này khẳng định tính khả thi của các phương pháp tiếp cận, hướng tới việc phát triển các hệ thống phát hiện tin giả chính xác và hiệu quả hơn trong thực tế.

5. Đóng góp về mặt kinh tế - xã hội, giáo dục và đào tạo, an ninh, quốc phòng và khả năng áp dụng của đề tài:

Nghiên cứu này góp phần nâng cao nhận thức cộng đồng, hỗ trợ kiểm soát tin giả, giảm tác động tiêu cực của thông tin sai lệch và bảo vệ an ninh thông tin. Trong giáo dục, kết quả có thể ứng dụng vào giảng dạy AI và NLP. Về an ninh - quốc phòng, mô hình giúp giám sát, sàng lọc nội dung sai lệch, hạn chế thao túng dư luận. Khả năng áp dụng rộng rãi của nghiên cứu không chỉ dừng lại ở báo chí, mạng xã hội mà còn mở rộng sang phát hiện lừa đảo trực tuyến, giám sát thông tin y tế và kiểm soát nội dung số.

6. Công bố khoa học của sinh viên từ kết quả nghiên cứu của đề tài (*ghi rõ tên tạp chí nếu có*) hoặc nhận xét, đánh giá của cơ sở đã áp dụng các kết quả nghiên cứu (*nếu có*):

MỤC LỤC

MỤC LỤC	1
DANH MỤC BẢNG BIỂU	3
DANH MỤC HÌNH VẼ	4
DANH MỤC TỪ VIẾT TẮT	5
LỜI MỞ ĐẦU	6
CHƯƠNG I: TỔNG QUAN ĐỀ TÀI.....	7
1.1 Lý do chọn đề tài	7
1.2 Câu hỏi nghiên cứu.....	7
1.3 Mục tiêu nghiên cứu	8
1.4 Đối tượng nghiên cứu.....	8
1.5 Phạm vi nghiên cứu	8
1.6 Sơ lược về phương pháp nghiên cứu.....	8
1.7 Ý nghĩa và đóng góp của nghiên cứu	9
CHƯƠNG 2: CƠ SỞ LÝ THUYẾT.....	11
2.1 Tổng quan tình hình nghiên cứu trong và ngoài nước	11
2.2 Khái niệm nghiên cứu	12
2.3 Học sâu (Deep Learning).....	12
2.3.1 Giới thiệu.....	12
2.3.2 Quy trình hoạt động.....	13
2.4 Lý thuyết nền tảng.....	16
2.4.1 Xử lý ngôn ngữ tự nhiên NLP (Natural Language Processing)	16
2.4.2 Mô hình CNN.....	18
2.4.3 Mô hình LSTM.....	20
2.4.4 Mô hình BERT	23
2.4.5 Phương pháp trích xuất đặc trưng TF-IDF	26
2.4.6 Word Cloud	27
Chương 3: PHƯƠNG PHÁP NGHIÊN CỨU	30
3.1 Quy trình nghiên cứu.....	30
3.1.1 Thu thập dữ liệu.....	30
3.1.2 Huấn luyện mô hình	30
3.1.3 Chuẩn bị dữ liệu	32

3.1.4 Tiền xử lý dữ liệu	32
3.1.5 Chia tập dữ liệu, xây dựng mô hình	37
3.2. Huấn luyện mô hình	38
3.2.1. Mô hình LSTM.....	38
3.2.2. Mô hình BERT	39
3.2.3. Mô hình CNN	41
3.3. Đánh giá mô hình	42
3.4. Kết quả thực nghiệm và phân tích kết quả	48
3.4.1. Công cụ thực nghiệm.....	48
3.4.2 Hiệu suất mô hình trên tập kiểm tra	49
3.4.3. Kết quả trực quan dữ liệu – WordCloud	50
CHƯƠNG 4 : KẾT LUẬN VÀ HƯỚNG PHÁT TRIỂN	55
4.1 Kết luận	55
4.2 Hạn chế của nghiên cứu	56
4.3 Đề xuất hướng nghiên cứu trong tương lai	57
TÀI LIỆU THAM KHẢO	59

DANH MỤC BẢNG BIỂU

Bảng 1. Danh sách các từ viết tắt	5
Bảng 3: Mô tả số lượng của bộ dữ liệu	30
Bảng 3. Mô tả về ma trận nhầm lẫn.....	46
Bảng 4. So sánh hiệu suất của ba mô hình	49
Bảng 5. So sánh thời gian chạy trên ba mô hình	50

DANH MỤC HÌNH VẼ

Hình 1. Mô hình minh họa quá trình xử lý ngôn ngữ tự nhiên	17
Hình 2. Sơ đồ minh họa phân tích cú pháp của một câu trong xử lý ngôn ngữ tự nhiên	17
Hình 3. Cấu trúc cơ bản của CNN.....	18
Hình 4. Mô hình LSTM.....	20
Hình 5. Sơ đồ minh họa kiến trúc của BERT	24
Hình 7. Ma trận nhầm lẫn mô hình LSTM.....	39
Hình 8. Ma trận nhầm lẫn mô hình BERT	40
Hình 9. Ma trận nhầm lẫn mô hình CNN	41
Hình 10. Kết quả thể hiện trực quan các từ xuất hiện nhiều	52

DANH MỤC TỪ VIẾT TẮT

1	BERT	Bidirectional Encoder Representations from Transformers
2	CNN	Convolutional Neural Network
3	DL	Deep Learning
4	EDA	Exploratory Data Analysis
5	TF-IDF	Term Frequency - Invert Document Frequency
6	KNN	K-Nearest Neighbors
7	LSTM	Long Short Term Memory
8	ML	Machine Learning
9	NLP	Natural Language Processing
10	RNN	Recurrent Neural Network
11	SVM	Support Vector Machine

Bảng 1. Danh sách các từ viết tắt

LỜI MỞ ĐẦU

Trong cuộc sống hiện nay, dưới tác động mạnh mẽ của công nghệ số, Internet và mạng xã hội đã trở thành cầu nối đưa thông tin lan truyền với tốc độ chóng mặt. Tuy nhiên, cùng với sự bùng nổ thông tin là sự gia tăng đáng báo động của tin tức giả mạo (*fake news*), gây nhiễu loạn nhận thức, làm sai lệch quan điểm của công chúng và để lại những hệ lụy nghiêm trọng đối với xã hội, chính trị, kinh tế và cả y tế. Theo một báo cáo của Statista (2023), hơn 67% người dùng Internet toàn cầu đã tiếp xúc với tin tức giả ít nhất một lần, trong đó hơn 52% không thể phân biệt tin thật và tin giả. Tại Mỹ, nghiên cứu từ MIT Media Lab cho thấy tin giả lan truyền nhanh hơn 70% so với tin thật, chủ yếu do sự giật gân và hấp dẫn của chúng. Đặc biệt, trong những sự kiện quan trọng như bầu cử, khủng hoảng sức khỏe toàn cầu hay thiên tai, tin giả có thể thao túng dư luận, kích động hoang mang và dẫn đến những hậu quả khó lường.

Trước thực trạng này, việc phát triển các phương pháp tự động nhằm phát hiện và kiểm soát tin tức giả mạo trở thành một yêu cầu cấp thiết, đòi hỏi sự kết hợp giữa công nghệ hiện đại và các phương pháp phân tích dữ liệu thông minh. Nghiên cứu này hướng đến việc ứng dụng phương pháp học máy (Machine Learning), đặc biệt là mô hình Deep Learning để xây dựng một hệ thống nhận diện tin tức giả mạo một cách tự động, nhanh chóng và chính xác. Thông qua việc huấn luyện các mô hình học sâu như LSTM, CNN và BERT trên tập dữ liệu tin tức. Bên cạnh đó, nghiên cứu không chỉ tập trung vào việc phân loại tin giả, mà còn phân tích đặc điểm ngôn ngữ của từ ngữ hay xuất hiện trong tin giả.

Nghiên cứu và phát triển một mô hình phát hiện tin giả không chỉ góp phần giảm thiểu những tác động tiêu cực của tin giả đối với nhận thức của công chúng mà còn hỗ trợ các nền tảng truyền thông và mạng xã hội trong việc kiểm duyệt, quản lý nội dung một cách hiệu quả hơn. Bên cạnh đó, những kết quả thu được từ nghiên cứu sẽ là cơ sở quan trọng để nâng cao độ chính xác của các hệ thống nhận diện tin giả trong tương lai. Bằng cách ứng dụng công nghệ hiện đại kết hợp với phân tích ngôn ngữ chuyên sâu, nghiên cứu này kỳ vọng sẽ góp phần xây dựng một hệ sinh thái thông tin minh bạch, đáng tin cậy, giúp hạn chế sự lan truyền của tin tức giả mạo và nâng cao chất lượng thông tin đối với xã hội.

CHƯƠNG I: TỔNG QUAN ĐỀ TÀI

1.1 Lý do chọn đề tài

Với sự phát triển mạnh mẽ của công nghệ thông tin và Internet như hiện nay, thông tin đã và đang được lan truyền một cách nhanh chóng trên tất cả các nền tảng xã hội và nhiều trang thông tin điện tử. Điều này không chỉ mang lại lợi ích trong việc chia sẻ kiến thức và kết nối con người, mà còn gây ra một thách thức rất lớn đối với việc kiểm soát chất lượng thông tin khi ngày càng có số lượng lớn thông tin giả (fake news), thông tin sai lệch. Theo số liệu, từ đầu năm 2021 đến ngày 28/3/2022, Trung tâm Xử lý tin giả Việt Nam đã nhận được 4.107 tin báo về thông tin sai sự thật, 502 tin xấu độc. Hậu quả của tin giả (fake news) không chỉ làm nhiễu loạn thông tin ở mỗi cá nhân mà nó còn ảnh hưởng đến tổ chức thậm chí có thể đe dọa đến an ninh quốc gia. Tin tức giả chỗ này chặn chưa xong thì tin tức giả ở nhiều chỗ khác đã mọc lên như nấm sau mưa. Nó như con virus, lan truyền mạnh mẽ và gây ra nhiều ảnh hưởng đến cách suy nghĩ cũng như quyết định của con người bởi vì việc ra quyết định dựa vào thông tin. Thêm vào đó, tin giả (fake news) còn tác động đến lòng tin của các độc giả, họ sẽ luôn ở trong trạng thái ngờ vực, đa nghi hơn và đặc biệt là làm cho họ mất niềm tin vào truyền thông. Tin giả (fake news) hay còn được gọi là *tin rác* hoặc *tin tức giả mạo* giả mạo là thông tin sai lệch hoặc gây hiểu lầm được trình bày dưới nhiều dạng thể nên rất khó để xác định tin giả đối với người bình thường và ngay cả đối với người có hiểu biết sâu về lĩnh vực đó thì kết quả cũng có thể không chính xác.

Vì vậy, việc nghiên cứu và phát triển các công cụ và phương pháp hiệu quả để xác thực tin giả là vô cùng cần thiết. Đó là một nhiệm vụ quan trọng và thách thức lớn để có thể đảm bảo tính toàn vẹn của thông tin.

1.2 Câu hỏi nghiên cứu

1. Các ngôn ngữ và đặc điểm ngôn ngữ nào thường xuất hiện trong tin giả?
2. Những phương pháp tiền xử lý dữ liệu nào phù hợp nhất để chuẩn bị dữ liệu cho mô hình học sâu?
3. Mô hình học sâu nào mang lại hiệu suất tốt nhất trong việc xác thực tin giả?
4. Các yếu tố nào ảnh hưởng đến độ chính xác của mô hình trong việc nhận diện tin giả?
5. Các phương pháp đánh giá mô hình nào phù hợp nhất để đo lường hiệu quả của các mô hình phát hiện tin giả?

6. Liệu có thể áp dụng mô hình học sâu để phát hiện tin giả trong ngôn ngữ tiếng Việt hiệu quả không?
7. Những thách thức lớn nhất trong việc phát hiện tin giả bằng mô hình học sâu là gì?

1.3 Mục tiêu nghiên cứu

Mục tiêu chính của đề tài này là nhận dạng được các đặc điểm của tin tức giả sử dụng mô hình học sâu (deep learning) nhằm tăng cường khả năng để xác thực tin giả trên các nền tảng trực tuyến. Qua đó giúp người dùng nhận diện và loại bỏ các nguồn tin không đáng tin cậy.

1.4 Đối tượng nghiên cứu

Đối tượng nghiên cứu của đề tài bao gồm bộ dữ liệu về tin giả và tin thật, mô hình học sâu được sử dụng trong bài và các từ vựng, cụm từ và đặc điểm ngôn ngữ trong tin giả.

1.5 Phạm vi nghiên cứu

Phạm vi nghiên cứu của đề tài bao gồm:

- Thu thập và xử lý dữ liệu: Thu thập một lượng lớn dữ liệu từ các nguồn tin tức chính thống và không chính thống, bao gồm cả tin giả và tin thật. Với EDA từ đó tiến xử lý dữ liệu như gỡ bỏ nhiễu, chuẩn hóa văn bản và trích xuất các đặc trưng phù hợp.
- Nghiên cứu các mô hình học sâu (Deep Learning) như LSTM, BERT, CNN cho việc xác thực tin giả.
- Triển khai mô hình và đánh giá tính hiệu quả của mô hình từ đó đưa ra những kết luận chính xác nhất cũng như tối ưu hóa mô hình.

1.6 Sơ lược về phương pháp nghiên cứu

Đề tài tập trung vào hướng nghiên cứu phương pháp tối ưu nhất cho bài toán định nghĩa và nhận biết các bài báo, tin tức giả. Sử dụng một tập hợp các phương pháp và kỹ thuật giúp đảm bảo mô hình học máy có thể đánh giá một cách hiệu quả. Nội dung nghiên cứu của đề tài như sau:

- Nghiên cứu và xem xét các kỹ thuật có thể giúp định nghĩa thế nào là tin tức giả, các kỹ thuật xử lý ngôn ngữ tự nhiên đã được công bố trước đó, gần hoặc

sát với chủ đề của đề tài đặt ra, từ các phương pháp giúp loại bỏ nhiễu, chuẩn hóa văn bản, phân tách các yếu tố như stop words không có ý nghĩa của bộ dữ liệu, ở đây cụ thể là đối với các bài báo/tin tức tiếng Việt.

- Thu thập bộ dữ liệu, để tiến hành thực hiện việc huấn luyện các mô hình phân tích, nhóm sẽ thu thập bộ dữ liệu tin tức tiếng Việt có thể là “thật” hoặc “giả” từ các trang báo và mạng xã hội có các yếu tố cần thiết để phù hợp với đề tài đã chọn.
- Trước tiên, nhóm sẽ định nghĩa khía cạnh tin tức giả áp dụng EDA chi tiết để xác định các yếu tố tiềm ẩn ảnh hưởng đến việc phân biệt tin thật và giả, kiểm tra cấu trúc dữ liệu, phân tích phân phối dữ liệu, phân tích tần suất từ, phân tích ngữ nghĩa và phân tích tương quan từ đó giúp hỗ trợ cho việc xây dựng mô hình học sâu một cách hiệu quả.

1.7 Ý nghĩa và đóng góp của nghiên cứu

Trong những năm gần đây, sự phát triển của mạng xã hội có thể nói đã bùng nổ hơn bao giờ hết, tạo điều kiện rất lớn để tất cả mọi người giao tiếp và đón nhận các thông tin qua mạng. Thông qua phương pháp để nhận biết được tin giả, khám phá và ứng dụng các đặc trưng mới chưa được sử dụng phổ biến trong các nghiên cứu trước đây, việc phát triển mô hình học sâu của đề tài mong muốn đem lại những lợi ích như: Giúp người dùng nâng cao khả năng trong bước tiếp nhận và phân biệt tin tức, hạn chế được việc tiếp thu và lan truyền thông tin bị sai lệch. Phòng chống các nguồn tin giả hiệu quả giúp các cơ quan chức năng trong việc giám sát và xử lý các nguồn tin không chính thống, giữ gìn an ninh mạng và trật tự xã hội. Việc triển khai thành công nghiên cứu này sẽ góp phần tạo ra một môi trường thông tin trong sạch và đáng tin cậy. Nghiên cứu cũng sẽ cung cấp thêm dữ liệu và kết quả phân tích về hiệu quả của các mô hình học sâu trong việc phát hiện tin giả, đóng góp vào kho tàng kiến thức trong lĩnh vực xử lý ngôn ngữ tự nhiên (NLP) và học sâu. Kết quả nghiên cứu có thể được sử dụng làm tài liệu tham khảo cho các nghiên cứu sau này, mở ra nhiều hướng nghiên cứu mới.

CHƯƠNG 2: CƠ SỞ LÝ THUYẾT

2.1 Tổng quan tình hình nghiên cứu trong và ngoài nước

Nghiên cứu của [7] đã phát hiện tin tức giả bằng phương pháp học máy. Để xử lý văn bản, các tác giả đã sử dụng các phương pháp NLP. Trước khi dự đoán các tác giả sẽ phân tích ngữ nghĩa để kiểm tra xem các đầu vào của tập dữ liệu có ngữ pháp chính xác hay không và sau đó là sử dụng hai mô hình Naive Bayes và Support Vector Machine (SVM) để dự đoán và kết quả độ chính xác cho thấy rằng SVM cho độ chính xác cao hơn Naive Bayes.

Trong nghiên cứu của [14] đã phát hiện các tin tức giả từ phương tiện truyền thông bằng cách sử dụng các phân loại học máy. Các tác giả đã sử dụng các mô hình KNN, Logistic Regression, Naive Bayes, Decision Tree và SVM để xác định tin giả với tin thật trong một tập dữ liệu nhất định. Kết quả thu được là độ chính xác của Logistic Regression là cao nhất đến 90,46%, 89,98% cho KNN, 89,33% cho SVM, 86,89% cho Naive Bayes và 73,33% cho Decision Tree.

Nghiên cứu của [15] đã phát hiện tin tức ở Việt Nam bằng các mô hình của Deep Learning cụ thể là các mô hình LSTM, Bi-LSTM và CNN-BiLSTM. Nghiên cứu sử dụng dữ liệu tin giả tiếng Việt thu thập từ các trang báo điện tử và bộ dữ liệu tiếng Anh “True, Fake” (được dịch sang tiếng Việt). Kết quả thu được mô hình CNN- BiLSTM thể hiện hiệu quả nhất trong số mô hình được dùng trong việc phát hiện tin giả.

Nghiên cứu của [9] đã phát hiện tin tức giả mạo trên mạng xã hội bằng cách sử dụng Machine Learning và Deep Learning để đạt hiệu suất tốt hơn. Đối với học máy truyền thống nhóm tác giả đã sử dụng các phương pháp như SVM và Naive Bayes còn đối với phương pháp Deep Learning nhóm tác giả sử dụng các mạng nơ-ron như CNN và RNN để học các mẫu phức tạp từ dữ liệu. Kết quả nghiên cứu cho thấy các phương pháp học sâu có thể đạt được độ chính xác cao trong việc phát hiện tin giả. Tuy nhiên, vẫn còn nhiều thách thức cần giải quyết, chẳng hạn như sự phát triển của các kỹ thuật mới để tạo ra tin giả tinh vi hơn và sự thiếu hụt dữ liệu huấn luyện chất lượng cao.

Nghiên cứu của [4], nhóm tác giả đã trình bày hai kỹ thuật ứng dụng rộng rãi hiện nay đó là kỹ thuật học máy dựa trên các phương pháp truyền thống và học sâu. Hai kỹ thuật này đều dựa trên phân tích nội dung bản tin và bước đầu đã mang lại những kết quả tích cực. Tuy nhiên, đây là bài báo mang tính chất nghiên cứu tổng quan nên nhóm

tác giả chỉ dừng ở mức tổng hợp, phân tích, nhận định và trình bày lại những kết quả nghiên cứu đã có trước đó.

Nghiên cứu của [1], nhóm tác giả đã nghiên cứu, xây dựng và đánh giá các mô hình học máy cũng như học sâu bao gồm: Naive Bayes (NB), Support Vector Machine (SVM), mạng hồi quy Long Short Term Memory (LSTM) để giải quyết bài toán phát hiện tin giả mạo trên bộ dữ liệu tiếng Việt. Kết quả của nghiên cứu rất khả quan với tỉ lệ chính xác tập kiểm thử trên 88% cho bộ dữ liệu tiếng việt VFND mở ra các hướng nghiên cứu ứng dụng nhận dạng tin tức giả mạo trong tiếng Việt.

Nghiên cứu của [16], nhóm nghiên cứu đã đề xuất một mô hình phát hiện tin tức giả sử dụng kỹ thuật phân tích n-gram và học máy. Qua điều tra và so sánh hai kỹ thuật trích xuất đặc điểm khác nhau và sáu kỹ thuật phân loại máy khác nhau. Đánh giá thử nghiệm mang lại hiệu suất tốt nhất bằng cách sử dụng Tần số tài liệu đảo ngược tần số thuật ngữ (TF-IDF) làm kỹ thuật trích xuất đặc điểm và Máy vector hỗ trợ tuyến tính (LSVM) làm công cụ phân loại, với độ chính xác 92%.

2.2 Khái niệm nghiên cứu

Thuật ngữ "tin giả" là một khái niệm tương đối mới và cho đến nay vẫn chưa có một định nghĩa chung được thống nhất về tin tức giả mạo hay tin giả (Fake News). Theo từ điển Oxford "Tin giả là thông tin sai sự thật được phát sóng hoặc xuất bản dưới dạng tin tức nhằm mục đích lừa đảo hoặc có động cơ chính trị. Tin giả tạo ra sự nhầm lẫn đáng kể của công chúng về các sự kiện hiện tại. Tin giả bùng nổ trên phương tiện truyền thông xã hội, đang xâm nhập vào các kênh truyền thông chính". Học giả về truyền thông Nolan Higdon đã định nghĩa "Tin tức giả là nội dung sai sự thật hoặc gây hiểu lầm được trình bày dưới dạng tin tức và được truyền đạt dưới các định dạng bao gồm truyền thông nói, viết, in, điện tử và kỹ thuật số" [13]. Tin tức giả mạo cũng đề cập đến những câu chuyện bịa đặt có rất ít hoặc không có sự thật và khó có thể xác minh được. Thậm chí rộng hơn, sau kỳ bầu cử tổng thống Mỹ năm 2020, người ta đã mở rộng ý nghĩa của "tin tức giả" để bao gồm cả các tin tức tiêu cực về niềm tin và hành động cá nhân của họ.

2.3 Học sâu (Deep Learning)

2.3.1 Giới thiệu

Học sâu (Deep Learning) là một lĩnh vực thuộc trí tuệ nhân tạo (Artificial Intelligence – AI) và học máy (Machine Learning – ML), tập trung vào việc sử dụng mạng nơ-ron nhân tạo nhiều lớp để mô phỏng cách con người xử lý dữ liệu. Với khả

năng tự động trích xuất và học đặc trưng từ dữ liệu, học sâu đã trở thành một công nghệ quan trọng trong nhiều lĩnh vực như thị giác máy tính, xử lý ngôn ngữ tự nhiên (NLP), và phân tích dữ liệu lớn.

Mô hình học sâu hoạt động dựa trên mạng nơ-ron nhân tạo nhiều lớp (Deep Neural Networks – DNNs), bao gồm một hoặc nhiều lớp ẩn giữa lớp đầu vào và lớp đầu ra. Quá trình học của mạng được thực hiện thông qua việc điều chỉnh các trọng số (weights) giữa các nơ-ron bằng thuật toán lan truyền ngược (Backpropagation). Các lớp trong mô hình có thể bao gồm:

- Lớp đầu vào (Input Layer): Nhận dữ liệu thô từ nguồn đầu vào.
- Lớp ẩn (Hidden Layers): Xử lý dữ liệu bằng cách học các đặc trưng quan trọng thông qua các phép toán tuyến tính và phi tuyến tính. Một số loại phổ biến là mạng tích chập (CNN – Convolutional Neural Networks) dùng cho xử lý ảnh và mạng hồi tiếp (RNN, LSTM, Transformer) dùng trong xử lý chuỗi như văn bản.
- Lớp đầu ra (Output Layer): Xuất kết quả dự đoán dựa trên dữ liệu đã học được.

Nhờ những bước tiến trong máy học, nhiều lĩnh vực như y tế, tài chính, giao thông, giải trí và tiếp thị đã có sự phát triển vượt bậc. Không chỉ giúp tối ưu hóa hiệu suất và độ chính xác của các hệ thống hiện có, máy học còn mở ra nhiều cơ hội và tiềm năng mới, góp phần thúc đẩy những đột phá công nghệ trong tương lai. Khi lượng dữ liệu ngày càng lớn và thuật toán ngày càng phát triển, máy học sẽ tiếp tục trở thành một trong những công nghệ cốt lõi, định hình thế giới số trong thời đại hiện nay.

2.3.2 Quy trình hoạt động

Học sâu vận hành thông qua một quy trình gồm các bước chính như sau:

1. Thu thập và tiền xử lý dữ liệu

Dữ liệu đóng vai trò cốt lõi trong hiệu suất của mô hình học sâu. Việc thu thập và xử lý dữ liệu được thực hiện theo các bước sau:

Thu thập dữ liệu: Tập hợp dữ liệu từ các nguồn khác nhau như cảm biến, cơ sở dữ liệu, tài liệu văn bản, hình ảnh hoặc dữ liệu trực tuyến.

Làm sạch dữ liệu: Loại bỏ các giá trị bị thiếu, dữ liệu trùng lặp hoặc các yếu tố không cần thiết để tăng độ chính xác của mô hình.

Chuẩn hóa dữ liệu: Chuyển đổi dữ liệu về dạng thống nhất, đảm bảo các đặc trưng có giá trị tương đồng để tránh ảnh hưởng đến quá trình huấn luyện.

Gán nhãn dữ liệu: Trong các bài toán có giám sát, dữ liệu cần được phân loại hoặc gán nhãn để mô hình có thể học được mối quan hệ giữa đầu vào và đầu ra.

2. Xây dựng mô hình học sâu

Việc xây dựng mô hình đòi hỏi sự lựa chọn kiến trúc phù hợp với bài toán cần giải quyết. Các quyết định quan trọng bao gồm:

Chọn loại mô hình: Tùy theo đặc điểm của dữ liệu, có thể sử dụng mạng nơ-ron tích chập (CNN – Convolutional Neural Networks) cho xử lý hình ảnh, văn bản, mạng hồi tiếp (RNN, LSTM, Transformer) cho xử lý chuỗi thời gian và văn bản, hoặc các mô hình lai kết hợp nhiều kiến trúc khác nhau.

Xác định số lượng lớp và nơ-ron: Thiết lập số lượng lớp ẩn, số nơ-ron trên mỗi lớp, và lựa chọn hàm kích hoạt phù hợp như ReLU, Sigmoid hay Softmax.

Cấu hình tham số mô hình: Gồm trọng số ban đầu, tốc độ học (learning rate) và các siêu tham số (hyperparameters) khác để tối ưu hiệu suất học.

3. Huấn luyện mô hình

Quá trình huấn luyện là giai đoạn quan trọng nhất, giúp mô hình học từ dữ liệu để đưa ra dự đoán chính xác. Các bước chính gồm:

- Cung cấp dữ liệu huấn luyện: Dữ liệu được chia thành các lô (batch) nhỏ để tăng hiệu suất tính toán.
- Lan truyền tiến (Forward Propagation): Dữ liệu đầu vào đi qua các lớp nơ-ron và tạo ra đầu ra dự đoán.
- Tính toán hàm mất mát (Loss Function): Đo lường sai số giữa kết quả dự đoán và giá trị thực tế.
- Lan truyền ngược (Backpropagation): Điều chỉnh trọng số của mô hình dựa trên sai số tính toán, bằng cách sử dụng các thuật toán tối ưu hóa như Gradient Descent, Adam hoặc RMSprop.
- Lặp lại quá trình trên nhiều vòng lặp (epochs): Tiếp tục điều chỉnh mô hình cho đến khi sai số giảm xuống mức chấp nhận được hoặc mô hình đạt độ hội tụ mong muốn.

4. Đánh giá và tinh chỉnh mô hình

Sau khi huấn luyện, mô hình cần được kiểm tra và điều chỉnh để đảm bảo hiệu suất hoạt động ổn định:

Đánh giá trên tập kiểm thử: Sử dụng dữ liệu chưa từng xuất hiện trong quá trình huấn luyện để đánh giá khả năng tổng quát hóa của mô hình.

Phát hiện và điều chỉnh lỗi: Kiểm tra xem mô hình có bị quá khớp (overfitting) hay chưa đủ khớp (underfitting), từ đó áp dụng các kỹ thuật như dropout, batch normalization hoặc điều chỉnh siêu tham số.

Cải thiện hiệu suất: Thử nghiệm với các kiến trúc mạng khác nhau hoặc tối ưu hoá thuật toán huấn luyện để nâng cao độ chính xác.

5. Triển khai và ứng dụng mô hình

Sau khi đạt được hiệu suất mong muốn, mô hình được triển khai vào ứng dụng thực tế.

Triển khai trên nền tảng phù hợp: Mô hình có thể được tích hợp vào hệ thống phần mềm, ứng dụng web, thiết bị di động hoặc dịch vụ đám mây.

Giám sát hiệu suất: Theo dõi hoạt động của mô hình trên dữ liệu thực tế để phát hiện sai lệch và điều chỉnh kịp thời.

Cập nhật và tái huấn luyện: Khi dữ liệu mới xuất hiện, mô hình có thể được cập nhật hoặc huấn luyện lại để đảm bảo độ chính xác và tính thích ứng cao.

Học sâu đóng vai trò quan trọng trong việc phát hiện và phân loại tin tức giả thông qua khai thác các đặc trưng ngữ nghĩa, cấu trúc và ngữ cảnh của văn bản. Một trong những ứng dụng chính của học sâu trong lĩnh vực này là xử lý và biểu diễn văn bản, trong đó các phương pháp như Word Embedding (Word2Vec, GloVe, FastText) hoặc các mô hình ngữ cảnh tiên tiến (BERT, GPT) được sử dụng để chuyển đổi văn bản thành dạng số hóa. Điều này giúp máy có thể hiểu và phân tích nội dung một cách hiệu quả hơn. Các mô hình mạng nơ-ron hồi tiếp như RNN, LSTM, GRU hay Transformer có khả năng học và biểu diễn ngữ nghĩa của câu, giúp phát hiện các dấu hiệu bất thường trong tin tức.

Bên cạnh việc phân tích nội dung, học sâu còn hỗ trợ phát hiện các mẫu tin giả thông qua đặc điểm ngữ nghĩa và phong cách diễn đạt. Các mô hình học từ dữ liệu huấn luyện để phân biệt tin thật và tin giả dựa trên giọng điệu, cảm xúc và mức độ giật gân

của bài viết. Việc phân tích cảm xúc của văn bản giúp xác định xem tin tức có xu hướng kích động hay mang tính trung lập.

Ngoài nội dung văn bản, mô hình học sâu còn có thể kiểm tra độ tin cậy của nguồn tin bằng cách đối chiếu với các nguồn chính thống hoặc sử dụng các thuật toán xác thực thông tin. Thông qua việc phân tích tác giả và lịch sử đăng tải bài viết, hệ thống có thể đánh giá mức độ uy tín của nguồn tin và nhận diện các xu hướng lan truyền thông tin không chính xác. Không chỉ dừng lại ở việc đánh giá nội dung tin tức, học sâu còn có thể phân tích hành vi người dùng, xác định các mẫu chia sẻ tin tức giả trên mạng xã hội. Các thuật toán có thể phát hiện tài khoản hoặc nhóm người dùng có xu hướng lan truyền thông tin sai lệch, từ đó đưa ra các biện pháp cảnh báo kịp thời. Đồng thời, việc theo dõi mức độ tương tác của người đọc thông qua bình luận và chia sẻ cũng giúp đánh giá mức độ ảnh hưởng của bài viết trong cộng đồng.


Một trong những điểm mạnh của học sâu là khả năng hợp nhất nhiều nguồn dữ liệu để nâng cao độ chính xác trong việc phát hiện tin tức giả. Các mô hình có thể kết hợp thông tin từ văn bản, hình ảnh và video để kiểm tra mức độ chân thực của nội dung. Chẳng hạn, hệ thống có thể xác minh xem hình ảnh được sử dụng trong bài báo có bị chỉnh sửa hoặc lấy từ bối cảnh không liên quan hay không. Ngoài ra, việc so sánh nội dung bài viết với các nguồn tin đáng tin cậy cũng giúp xác minh tính chính xác của thông tin được truyền tải.

Có thể nói, học sâu mang lại nhiều lợi ích trong việc phát hiện tin tức giả bằng cách phân tích ngữ nghĩa văn bản, xác minh nguồn tin, đánh giá hành vi người dùng và kết hợp nhiều nguồn dữ liệu. Việc áp dụng các mô hình tiên tiến như CNN, RNN, LSTM và Transformer giúp nâng cao khả năng phát hiện và ngăn chặn thông tin sai lệch một cách tự động và chính xác, góp phần xây dựng môi trường thông tin minh bạch và đáng tin cậy hơn.

2.4 Lý thuyết nền tảng

2.4.1 Xử lý ngôn ngữ tự nhiên NLP (Natural Language Processing)

Xử lý ngôn ngữ tự nhiên (NLP) là một lĩnh vực quan trọng trong khoa học máy tính và trí tuệ nhân tạo, giúp máy tính có thể hiểu, phân tích và tạo ra ngôn ngữ tự nhiên một cách tự động. NLP có vai trò thiết yếu trong nhiều ứng dụng quen thuộc hằng ngày, từ chatbot, dịch máy đến tóm tắt văn bản.



Hình 1. Mô hình minh họa quá trình xử lý ngôn ngữ tự nhiên

NLP bao gồm các khía cạnh chính:

Xử lý tiếng nói (Speech Processing): Tập trung vào việc nhận dạng và hiểu các dạng âm thanh từ giọng nói của con người.

Xử lý văn bản (Text Processing): Nhằm hiểu và tạo ra văn bản tự nhiên, bao gồm việc phân tích ý nghĩa và cấu trúc câu.


Trong các ứng dụng NLP, thường có một số phương pháp tiếp cận phổ biến như:

Phương pháp có giám sát: Hệ thống được huấn luyện trên dữ liệu đã gắn nhãn để có thể phân loại và dự đoán dữ liệu mới.

Phương pháp không giám sát: Sử dụng các kỹ thuật thống kê để phát hiện và phân tích dữ liệu chưa được gắn nhãn.

Hiểu ngôn ngữ tự nhiên (NLU - Natural Language Understanding): Tập trung vào việc phân tích ngữ nghĩa và ngữ cảnh của ngôn ngữ tự nhiên.

Tạo ngôn ngữ tự nhiên (NLG - Natural Language Generation): Tạo ra văn bản tự nhiên dựa trên các quy tắc và dữ liệu có sẵn.



Hình 2. Sơ đồ minh họa phân tích cú pháp của một câu trong xử lý ngôn ngữ tự nhiên


(nguồn: Internet)

NLP ngày càng đóng vai trò quan trọng trong việc nâng cao trải nghiệm người dùng, đồng thời góp phần phát triển các ứng dụng thông minh trong nhiều lĩnh vực, từ công nghệ đến dịch vụ khách hàng.

Trong đề tài phân loại tin tức giả, NLP đóng vai trò quan trọng vì nó giúp mô hình hiểu nội dung văn bản, phát hiện mẫu ngữ nghĩa và phân biệt giữa tin thật và tin giả. Các mô hình CNN, RNN hay Transformer trong NLP có thể được sử dụng để trích xuất đặc trưng từ văn bản, phát hiện các đặc điểm bất thường trong câu chữ, giọng điệu hoặc nguồn tin. Ngoài ra, các kỹ thuật như phân tích cảm xúc, nhận diện mẫu từ vựng, và kiểm tra nguồn có thể giúp nâng cao độ chính xác của hệ thống phân loại tin tức giả.

2.4.2 Mô hình CNN

Mạng Nơ-ron Tích Chập (CNN - Convolutional Neural Network) là một mô hình học sâu phổ biến, đặc biệt hiệu quả trong xử lý dữ liệu hình ảnh và chuỗi văn bản. CNN hoạt động bằng cách trích xuất đặc trưng từ dữ liệu đầu vào thông qua các lớp tích chập, giúp tự động nhận diện các mẫu đặc trưng quan trọng mà không cần trích xuất thủ công.



Hình 3. Cấu trúc cơ bản của CNN

Như sơ đồ trên minh họa, mạng nơ-ron tích chập bao gồm các thành phần chính: Input, các lớp Convolutional + ReLU, Pooling, và Fully-connected layer. Dữ liệu đầu vào được đưa vào lớp tích chập (Convolutional layer), nơi các bộ lọc quét qua để trích xuất đặc trưng, sau đó áp dụng hàm kích hoạt ReLU để tăng tính phi tuyến. Tiếp theo, lớp tổng hợp (Pooling layer) giúp giảm kích thước dữ liệu nhưng vẫn giữ được thông tin quan trọng. Quá trình này có thể lặp lại nhiều lần để trích xuất đặc trưng ở nhiều cấp độ khác nhau. Cuối cùng, dữ liệu đi qua Fully-connected layer để tổng hợp và đưa ra dự đoán. Trong xử lý văn bản, mô hình này có thể sử dụng Word Embedding làm đầu vào, bộ lọc trong lớp tích chập quét theo chiều ngang để phát hiện n-gram, và Max Pooling

giúp chọn các đặc trưng quan trọng nhất trước khi phân loại nội dung (ví dụ: tin giả/tin thật hoặc cảm xúc tích cực/tiêu cực).

Trong lĩnh vực phân tích và phát hiện tin giả, CNN đóng vai trò quan trọng trong việc xác định dấu hiệu gian lận từ nội dung văn bản và hình ảnh. Với khả năng học sâu, CNN giúp cải thiện độ chính xác của hệ thống kiểm duyệt tin tức, góp phần hạn chế sự lan truyền thông tin sai lệch.

Cấu trúc của mô hình CNN. Mô hình CNN bao gồm các phần chính sau:

a. Lớp tích chập (Convolutional Layer)

Đây là lớp quan trọng nhất, giúp trích xuất đặc trưng từ dữ liệu đầu vào. Các bộ lọc (filter) quét qua dữ liệu để phát hiện các đặc trưng như từ khóa quan trọng (đối với văn bản) hoặc đường viền, chi tiết trong ảnh (đối với hình ảnh). Kích hoạt bằng ReLU (Rectified Linear Unit) để giữ lại các đặc trưng có ý nghĩa.

b. Lớp Pooling (Max Pooling/Average Pooling)

Giảm kích thước dữ liệu nhằm giảm số lượng tham số, tăng tốc độ tính toán. Max Pooling giúp lấy giá trị quan trọng nhất trong vùng đặc trưng, giúp mô hình tập trung vào thông tin hữu ích.

c. Lớp Fully Connected (FC - Kết nối đầy đủ)

Tổng hợp các đặc trưng đã học được và đưa ra dự đoán. Dùng Softmax hoặc Sigmoid để phân loại tin giả và tin thật.

Khi áp dụng mô hình CNN, quá trình phân loại có thể được thực hiện dựa trên hai nguồn dữ liệu chính: văn bản và hình ảnh, trong đó phân tích văn bản là một phương pháp phổ biến để xác định mức độ tin cậy của nội dung tin tức. CNN có thể xử lý văn bản bằng cách chuyển đổi nội dung thành dạng số, sau đó sử dụng các lớp tích chập để phân tích cấu trúc và ngữ nghĩa của câu.

Quy trình thực hiện:

Trước tiên, văn bản cần được tiền xử lý để loại bỏ các yếu tố gây nhiễu như ký tự đặc biệt và stopwords, đồng thời chuẩn hóa dữ liệu để đảm bảo tính đồng nhất. Sau đó, văn bản được chuyển đổi thành dạng vector bằng các phương pháp như Word2Vec, GloVe hoặc BERT embedding, giúp mô hình có thể hiểu được ngữ nghĩa của từng từ và mối quan hệ giữa chúng.

CNN tiếp nhận dữ liệu đã được số hóa và sử dụng các lớp tích chập để trích xuất đặc trưng quan trọng. Các bộ lọc với kích thước khác nhau giúp mô hình có thể nhận

diện các n-gram quan trọng, đồng thời lớp Max Pooling được áp dụng nhằm chọn lọc những thông tin hữu ích nhất. Cuối cùng, các lớp Fully Connected được sử dụng để đưa ra dự đoán về tính xác thực của tin tức.


Ứng dụng của mô hình này trong phát hiện tin giả bao gồm việc nhận diện các bài viết có dấu hiệu giật gân, sai sự thật, cũng như xác định các nguồn tin không đáng tin cậy. Bên cạnh đó, CNN có thể kết hợp với các mô hình khác để tăng độ chính xác trong phân loại tin giả như:

CNN + RNN (LSTM, GRU): Xử lý văn bản hiệu quả hơn bằng cách ghi nhớ ngữ cảnh trước và sau.

CNN + Transformer (BERT, GPT): Hiểu sâu hơn về ngữ nghĩa và mối quan hệ giữa các từ trong câu.

2.4.3 Mô hình LSTM

Mạng nơ-ron hồi tiếp (Recurrent Neural Network - RNN) là một trong những mô hình quan trọng trong xử lý ngôn ngữ tự nhiên, tuy nhiên, nó gặp phải hạn chế lớn là vấn đề "quên" thông tin khi khoảng cách giữa các từ trong câu trở nên quá xa. Để giải quyết vấn đề này, LSTM (Long Short-Term Memory) đã được giới thiệu như một kiến trúc tiên tiến hơn của RNN, có khả năng lưu giữ thông tin dài hạn và khắc phục tình trạng mất mát thông tin trong quá trình lan truyền.



Hình 4. Mô hình LSTM

(Trích nguồn: Internet)

Qua hình minh họa, ta có thể thấy cấu trúc của LSTM. LSTM được xây dựng từ các khối nhớ (memory cells), trong đó có ba cổng chính để kiểm soát luồng thông tin:

- Cổng quên (Forget Gate): Xác định thông tin nào trong trạng thái cũ cần được loại bỏ.

$$f_t = \sigma(W_f \cdot [h_{t-1}, x_t] + b_f)$$

Trong đó, f_t là giá trị của cổng quên tại thời điểm t , W_f và b_f là trọng số và hệ số điều chỉnh của cổng quên, h_{t-1} là đầu ra của bước trước đó, và x_t là đầu vào hiện tại.

- Cổng nhập (Input Gate): Quyết định thông tin mới nào cần được lưu vào bộ nhớ.

$$i_t = \sigma(W_i \cdot [h_{t-1}, x_t] + b_i)$$

$$C_{\sim t} = \tanh(W_c \cdot [h_{t-1}, x_t] + b_c)$$

Giá trị i_t là mức độ thông tin mới được cập nhật vào bộ nhớ, còn $C_{\sim t}$ là trạng thái bộ nhớ tiềm năng được thêm vào.

- Cổng đầu ra (Output Gate): Điều chỉnh thông tin nào sẽ được đưa ra làm đầu ra của bước hiện tại.

$$o_t = \sigma(W_o \cdot [h_{t-1}, x_t] + b_o)$$

$$h_t = o_t \cdot \tanh(C_t)$$

Trong đó, o_t là giá trị điều khiển đầu ra, và h_t là đầu ra của tế bào bộ nhớ.

Trạng thái bộ nhớ tại thời điểm t được cập nhật như sau:

$$C_t = f_t \cdot C_{t-1} + i_t \cdot C_{\sim t}$$

Công thức này thể hiện cách LSTM lưu giữ và cập nhật thông tin theo thời gian. Nhờ các cổng trên, LSTM có thể lưu trữ thông tin quan trọng trong thời gian dài và loại bỏ những thông tin không cần thiết, giúp cải thiện khả năng xử lý các chuỗi dữ liệu dài.

LSTM bao gồm một chuỗi các ô nhớ (memory cells) vớ

Quy trình hoạt động của LSTM có thể được mô tả như sau:

Bước 1: Nhận đầu vào từ chuỗi dữ liệu.

Bước 2: Tại mỗi bước thời gian, thông tin từ bước trước được truyền vào.

Bước 3: Cổng quên quyết định dữ liệu nào trong bộ nhớ cần loại bỏ.

Bước 4: Cổng nhập chọn thông tin mới cần thêm vào bộ nhớ.

Bước 5: Cổng đầu ra quyết định phần nào của bộ nhớ sẽ được đưa ra làm đầu ra.

Bước 6: Tiếp tục quá trình trên cho toàn bộ chuỗi dữ liệu.

Ưu điểm của LSTM

- Xử lý tốt dữ liệu tuần tự dài hạn, không gặp phải vấn đề mất trí nhớ như RNN truyền thống.
- Giảm thiểu hiện tượng biến mất đạo hàm (vanishing gradient), giúp mô hình học hiệu quả hơn.
- Linh hoạt và có thể ứng dụng rộng rãi trong nhiều lĩnh vực khác nhau.

Nhược điểm của LSTM

- Cấu trúc phức tạp hơn so với RNN, đòi hỏi nhiều tài nguyên tính toán hơn.
- Huấn luyện chậm do số lượng tham số lớn.

Trong bối cảnh xử lý ngôn ngữ tự nhiên (NLP), LSTM đã chứng minh được tính hiệu quả vượt trội so với mạng nơ-ron hồi tiếp truyền thống (RNN) khi có khả năng ghi nhớ thông tin quan trọng và loại bỏ dữ liệu không cần thiết trong quá trình huấn luyện. Điều này đặc biệt hữu ích trong nhiệm vụ phân loại tin tức, nơi mà việc nhận diện các dấu hiệu bất thường trong văn bản đòi hỏi một mô hình có khả năng duy trì ngữ cảnh dài hạn và hiểu rõ cấu trúc ngữ nghĩa của ngôn ngữ.

Để áp dụng LSTM vào bài toán phân loại tin tức giả, quy trình xử lý dữ liệu được thực hiện theo một chuỗi các bước có hệ thống. Trước hết, dữ liệu văn bản cần được tiền xử lý nhằm loại bỏ các yếu tố gây nhiễu như ký tự đặc biệt, dấu câu và từ dừng. Đồng thời, văn bản được chuyển đổi sang dạng số hóa thông qua các phương pháp nhúng từ (word embedding) như Word2Vec, GloVe hoặc FastText, giúp mô hình có thể tiếp thu và hiểu ý nghĩa của từ ngữ trong bối cảnh cụ thể.

Sau quá trình tiền xử lý, dữ liệu được đưa vào mạng LSTM để mã hóa thông tin theo thời gian. Nhờ vào kiến trúc đặc trưng với ba cổng chính gồm cổng quên, cổng đầu vào và cổng đầu ra, LSTM có thể lựa chọn giữ lại hoặc loại bỏ thông tin tại mỗi bước thời gian. Điều này giúp mô hình học được các mối quan hệ ngữ nghĩa dài hạn trong văn bản, từ đó phát hiện những đặc điểm thường xuất hiện trong tin tức giả, chẳng hạn như ngôn ngữ mang tính kích động, thiếu căn cứ hoặc các cụm từ giật gân.

Trong quá trình huấn luyện, LSTM sẽ học cách phân biệt tin thật và tin giả dựa trên các mẫu ngữ nghĩa và phong cách diễn đạt. Khi tiếp nhận một bài báo mới, mô hình sẽ dựa vào các đặc trưng đã học để đánh giá và dự đoán tính xác thực của nội dung. Lớp đầu ra của mô hình thường sử dụng hàm kích hoạt Softmax để phân loại bài viết theo hai nhóm: tin thật hoặc tin giả, với xác suất tương ứng cho mỗi nhóm.


Việc ứng dụng LSTM trong đề tài sẽ mang lại nhiều lợi thế quan trọng. Trước hết, khả năng ghi nhớ và xử lý thông tin dài hạn giúp mô hình có thể nhận diện các dấu hiệu bất thường trong nội dung văn bản mà các mô hình truyền thống có thể bỏ sót. Hơn nữa, nhờ vào khả năng học tự động từ dữ liệu, mô hình có thể liên tục cải thiện độ chính xác mà không cần đến các quy tắc được thiết lập thủ công. Ngoài ra, LSTM còn có khả năng mở rộng, phù hợp để xử lý khối lượng lớn dữ liệu tin tức trên các nền tảng khác nhau, từ báo chí chính thống đến các bài đăng trên mạng xã hội.

Nhìn chung, ứng dụng LSTM vào bài nghiên cứu phân loại tin tức không chỉ giúp nâng cao hiệu suất phát hiện thông tin sai lệch mà còn góp phần xây dựng một môi trường truyền thông đáng tin cậy hơn. Với sự phát triển không ngừng của công nghệ học sâu, những cải tiến trong kiến trúc LSTM và các mô hình ngôn ngữ hiện đại có thể tiếp tục nâng cao độ chính xác của hệ thống nhận diện thông tin, từ đó góp phần hạn chế sự lan truyền của thông tin sai lệch trong xã hội.

2.4.4 Mô hình BERT

Sự phát triển của xử lý ngôn ngữ tự nhiên (NLP) đã tạo ra những bước đột phá đáng kể trong việc hiểu và phân tích văn bản. Trong số các mô hình hiện đại, BERT (Bidirectional Encoder Representations from Transformers) đã nổi lên như một phương pháp tiếp cận mạnh mẽ, giúp cải thiện đáng kể hiệu suất của các bài toán xử lý ngôn ngữ. BERT được thiết kế với khả năng học biểu diễn ngữ nghĩa của từ trong cả hai hướng trái và phải, cho phép mô hình hiểu sâu sắc hơn về ngữ cảnh của câu. Đặc điểm này giúp BERT vượt trội so với các mô hình truyền thống vốn chỉ xử lý thông tin theo một hướng cố định.

Một trong những điểm nổi bật của BERT là cơ chế xử lý song song hai chiều dựa trên kiến trúc Transformer. Không giống như các mô hình tiền nhiệm như LSTM hay RNN, vốn gặp hạn chế trong việc xử lý ngữ cảnh dài hạn do tính chất tuần tự, BERT có thể nắm bắt thông tin toàn diện từ cả hai phía của chuỗi văn bản ngay từ giai đoạn huấn luyện. Mô hình được tiền huấn luyện trên một lượng dữ liệu văn bản khổng lồ bằng cách sử dụng hai nhiệm vụ chính: Mô hình hóa ngôn ngữ bị che (Masked Language Model - MLM) và Dự đoán câu tiếp theo (Next Sentence Prediction - NSP). Nhờ vào cách tiếp cận này, BERT có khả năng hiểu rõ hơn ý nghĩa của từng từ trong một bối cảnh rộng lớn, từ đó cải thiện đáng kể độ chính xác trong các tác vụ xử lý ngôn ngữ tự nhiên.



Hình 5. Sơ đồ minh họa kiến trúc của BERT

(Trích nguồn: Internet)

Mô tả sơ đồ:

Khung màu vàng: Các từ trong câu đầu vào (I accessed accountt).

Tầng giữa (xanh dương): Các lớp mã hóa (encoder layers) của Transformer, trong đó từng token có thể liên kết với các token khác trong câu theo cơ chế self-attention hai chiều.

Tầng trên cùng (xanh lá cây): Các biểu diễn ngữ nghĩa ($T_1, T_2, \dots, T_N$) của các từ sau khi được BERT xử lý.

BERT được tiền huấn luyện trên một lượng lớn dữ liệu văn bản bằng hai phương pháp chính:

Mô hình hóa ngôn ngữ bị che (Masked Language Model - MLM) giúp BERT học cách dự đoán từ bị che trong một câu. Trong quá trình huấn luyện, một số từ trong câu sẽ bị thay thế bằng token đặc biệt [MASK], và mô hình phải dự đoán từ gốc dựa trên ngữ cảnh xung quanh. Nhờ đó, BERT có thể hiểu ý nghĩa của từ dựa trên cả phần trước và sau trong câu, thay vì chỉ dựa vào ngữ cảnh một chiều như các mô hình truyền thống.

Dự đoán câu tiếp theo (Next Sentence Prediction - NSP) giúp BERT học được mối quan hệ giữa các câu trong một văn bản. Cặp câu sẽ được đưa vào mô hình, trong đó một số cặp có quan hệ nối tiếp nhau, trong khi một số cặp là ngẫu nhiên. Mô hình được huấn luyện để phân biệt giữa hai loại câu này, giúp cải thiện khả năng hiểu văn bản trong các tác vụ như trả lời câu hỏi, tóm tắt và phân loại tin tức.

Sau quá trình tiền huấn luyện, BERT có thể được tinh chỉnh (fine-tuning) cho các nhiệm vụ cụ thể bằng cách bổ sung các lớp đầu ra phù hợp. Trong bài toán phân loại tin tức giả, BERT được huấn luyện để nhận diện các đặc điểm của tin thật và tin giả dựa trên tập dữ liệu gán nhãn trước đó.

Công thức chính trong BERT chủ yếu liên quan đến cơ chế self-attention, được tính toán thông qua các ma trận truy vấn (Query), khóa (Key) và giá trị (Value) như sau:

$$Attention(Q, K, V) = softmax \left(\frac{QK^T}{\sqrt{d_k}} \right) V$$

Trong đó, Q, K và V là các ma trận được ánh xạ từ đầu vào thông qua các trọng số huấn luyện được, còn d_k là số chiều của không gian từ vựng, giúp điều chỉnh mức độ ổn định của tính toán attention.

Trong nghiên cứu này, BERT được ứng dụng để phân tích nội dung bài báo nhằm xác định liệu một bài viết có chứa thông tin sai lệch hay không. Quá trình này thường bao gồm các bước chính như tiền xử lý dữ liệu, mã hóa văn bản, huấn luyện mô hình và đánh giá kết quả. Trước tiên, văn bản tin tức được làm sạch bằng cách loại bỏ các yếu tố gây nhiễu như ký tự đặc biệt, từ dừng và dấu câu. Tiếp theo, dữ liệu được mã hóa thành các vector biểu diễn thông qua mô hình BERT, giúp trích xuất thông tin ngữ nghĩa và mối quan hệ giữa các từ trong ngữ cảnh bài báo. Sau khi dữ liệu đã được biến đổi thành dạng số hóa, mô hình sẽ được huấn luyện với một tập hợp các bài báo đã được gán nhãn trước đó (tin thật hoặc tin giả). Nhờ vào khả năng hiểu ngữ cảnh sâu sắc, BERT có thể nhận diện những đặc điểm tinh vi của tin giả mà các mô hình truyền thống khó phát hiện. Những bài viết có dấu hiệu cường điệu hóa, ngôn ngữ giật gân hoặc thiếu tính nhất quán về mặt logic có thể được xác định chính xác hơn. Mô hình không chỉ dựa vào từ khóa cụ thể mà còn xem xét mối quan hệ giữa các từ trong toàn bộ văn bản, từ đó giảm thiểu tình trạng nhận diện sai do những từ ngữ có nghĩa đa chiều hoặc được sử dụng theo ngữ cảnh đặc biệt.

Sự ra đời của BERT đã mở ra nhiều cơ hội mới trong việc phát triển các hệ thống kiểm chứng thông tin, giúp hạn chế sự lan truyền của tin tức giả trong thời đại kỹ thuật số. Với khả năng mở rộng và cải thiện liên tục, BERT hứa hẹn sẽ tiếp tục đóng vai trò quan trọng trong nghiên cứu và ứng dụng NLP, đặc biệt là trong lĩnh vực phát hiện tin giả và bảo vệ môi trường thông tin trực tuyến.

2.4.5 Phương pháp trích xuất đặc trưng TF-IDF

Trong xử lý ngôn ngữ tự nhiên (NLP), TF-IDF (Term Frequency - Inverse Document Frequency) là một phương pháp quan trọng giúp đánh giá mức độ quan trọng của một từ trong một văn bản so với toàn bộ tập dữ liệu. Đây là một chỉ số kết hợp giữa tần suất xuất hiện của từ trong một văn bản cụ thể (TF) và mức độ phổ biến của từ đó trên toàn bộ tập hợp văn bản (IDF), giúp lọc ra những từ mang ý nghĩa phân biệt cao.

TF-IDF của một từ t trong một văn bản d được tính theo công thức:

$$TF - IDF(t, d) = TF(t, d) \times IDF(t)$$

Với:

- ❖ TF (Term Frequency): Tần suất xuất hiện của từ trong văn bản, tính theo:

$$TF(t, d) = \frac{f_{t,d}}{N_d}$$

Trong đó:

- $f_{t,d}$ là số lần từ t xuất hiện trong tài liệu d
- N_d là tổng số từ trong tài liệu d
- ❖ IDF (Inverse Document Frequency): Giúp giảm trọng số của các từ phổ biến và tăng trọng số của các từ hiếm, phản ánh mức độ đặc trưng của từ đó trong tập dữ liệu, được tính theo:

$$IDF(t) = \log \frac{N}{1 + DF_t}$$

Trong đó:

- N là tổng số tài liệu trong tập dữ liệu.
- $DF(t)$ là số tài liệu chứa từ t .

Trong nghiên cứu này, TF-IDF được ứng dụng nhằm hai mục tiêu chính: trước hết, nó được sử dụng để xác định các từ mang tính giật gân thường xuất hiện trong tin giả; sau đó, những từ này được trực quan hóa thông qua mô hình Word Cloud, cung cấp cái nhìn tổng quan về xu hướng sử dụng từ vựng trong các bài viết không chính thống.

Việc tính toán TF-IDF giúp loại bỏ các từ phổ biến không mang nhiều ý nghĩa, đồng thời nhấn mạnh những từ có mức độ xuất hiện cao trong tin giả nhưng hiếm gặp trong tin thật. Điều này có ý nghĩa đặc biệt quan trọng trong việc phát hiện các dấu hiệu đặc trưng của tin tức giả mạo, nơi mà các tiêu đề và nội dung thường được thiết kế nhằm thu hút sự chú ý của độc giả thông qua ngôn ngữ kích động, giật gân hoặc gây hoang mang.

Bên cạnh đó, giá trị TF-IDF của từng từ cũng được sử dụng làm đầu vào cho mô hình học máy, giúp nâng cao hiệu quả phân loại. Khi kết hợp TF-IDF với các mô hình như LSTM hay BERT, mô hình có thể học được các đặc trưng quan trọng của ngữ liệu, từ đó tăng cường độ chính xác trong việc dự đoán tính xác thực của tin tức.

Thông qua ứng dụng TF-IDF, nghiên cứu không chỉ cung cấp một phương pháp tiếp cận hiệu quả trong việc nhận diện tin giả mà còn góp phần xây dựng nền tảng cho các hệ thống kiểm chứng thông tin tự động, mở ra hướng nghiên cứu tiềm năng trong lĩnh vực xử lý ngôn ngữ tự nhiên và truyền thông số.

2.4.6 Word Cloud

Word Cloud, hay còn gọi là đám mây từ, là một phương pháp trực quan hóa dữ liệu văn bản, giúp biểu diễn tần suất xuất hiện của các từ trong một tập dữ liệu dưới dạng hình ảnh. Kích thước của mỗi từ trong Word Cloud tỷ lệ thuận với tần suất xuất hiện của nó trong văn bản, qua đó giúp nhanh chóng nhận diện các từ khóa quan trọng. Phương pháp này đặc biệt hữu ích trong các nghiên cứu xử lý ngôn ngữ tự nhiên (NLP), nơi mà việc phân tích tần suất từ vựng có thể cung cấp thông tin quan trọng về đặc điểm của một văn bản hoặc tập hợp văn bản nhất định.

❖ Cơ chế hoạt động:

Để xây dựng Word Cloud từ một tập dữ liệu văn bản, cần thực hiện một số bước tiền xử lý, bao gồm loại bỏ dấu câu, chuyển đổi văn bản về chữ thường, loại bỏ từ dừng (stop words) và chuẩn hóa từ vựng. Sau khi hoàn thành các bước này, tần suất xuất hiện của mỗi từ được tính toán bằng các phương pháp như:

❖ Tần suất từ xuất hiện trong văn bản (Term Frequency - TF)

❖ Trọng số TF-IDF (TF-IDF Score)

$$TF - IDF(t, d, D) = TF(t, d) \times IDF(t, D)$$

Trong đó:

$$IDF(t, D) = \log \frac{D}{1 + |\{d \in D: t \in d\}|}$$

với $|D|$ là tổng số tài liệu trong tập dữ liệu, và $|\{d \in D: t \in d\}|$ là số tài liệu chứa từ t .

Hàm Word Cloud trong thư viện wordcloud của Python cho phép trực quan hóa kết quả này. Cấu trúc sử dụng điển hình bao gồm:

```

from wordcloud import WordCloud
import matplotlib.pyplot as plt

wordcloud = WordCloud(width=800, height=400,
background_color="black").generate(text)
plt.figure(figsize=(10,5))
plt.imshow(wordcloud, interpolation="bilinear")
plt.axis("off")
plt.show()

```

Hàm WordCloud() có thể tùy chỉnh theo các thông số như màu sắc, phông chữ và cách sắp xếp từ, giúp tạo ra hình ảnh trực quan phù hợp với mục tiêu trong nghiên cứu về phân loại tin giả, Word Cloud được sử dụng để nhận diện những từ khóa có tần suất xuất hiện cao trong các bài viết không chính thống. Kết quả cho thấy rằng tin giả thường có xu hướng sử dụng các từ mang tính giật gân, làm quá vấn đề, trong khi tin thật có xu hướng sử dụng ngôn ngữ trung lập hơn.

Việc áp dụng Word Cloud vào đề tài không chỉ giúp minh họa trực quan đặc điểm từ vựng của tin giả mà còn hỗ trợ quá trình trích xuất đặc trưng cho các mô hình học máy. Khi kết hợp với trọng số TF-IDF, Word Cloud giúp xác định những từ quan trọng nhất trong tin giả so với tin thật, từ đó cải thiện độ chính xác của các mô hình phân loại. Điều này đóng vai trò quan trọng trong việc xây dựng các hệ thống phát hiện tin giả tự động, góp phần nâng cao chất lượng thông tin trên môi trường số.

Chương 3: PHƯƠNG PHÁP NGHIÊN CỨU

3.1 Quy trình nghiên cứu

3.1.1 Thu thập dữ liệu

Nhằm phục vụ nghiên cứu về phân loại tin thật và tin giả, nhóm đã tiến hành thu thập dữ liệu từ các nguồn báo điện tử, bao gồm các trang báo chính thống và các trang báo không chính thống. Mục tiêu của bộ dữ liệu là sử dụng các nội dung bài báo trong tập dữ liệu để phát hiện và nhận dạng tin tức giả.

Dữ liệu gồm 511 dòng chứa URL của các bài báo trên các trang báo điện tử Việt Nam sau đó được tổng hợp và chia thành 2 phân loại Real và Fake. Cụ thể, nhóm đã lấy dữ liệu từ các tờ báo uy tín như Báo Thanh Niên, Công An Nhân Dân, Tuổi Trẻ, Dân Trí, Lao Động, Nhân Dân, vốn được công nhận rộng rãi về độ tin cậy trong việc cung cấp thông tin.

Bên cạnh đó, để đảm bảo sự đa dạng của tập dữ liệu và phản ánh đầy đủ đặc điểm của tin giả, nhóm cũng thu thập nội dung từ các nguồn không chính thống như blog cá nhân, trang tin tự phát hoặc các nền tảng thường xuyên bị nghi ngờ lan truyền tin sai sự thật như Blogtamsu, Tin24h, CafeF,... Việc thu thập từ hai nhóm nguồn này giúp đảm bảo tính cân bằng của dữ liệu, tạo nền tảng vững chắc cho quá trình huấn luyện mô hình nhận diện tin giả.

STT	Label	Số lượng tin tức
1	Real	245
2	Fake	266

Bảng 3: Mô tả số lượng của bộ dữ liệu thu thập được


Bộ dữ liệu Stopword được sử dụng trong đề tài của nhóm thuộc sở hữu của tác giả Lê Văn Duyệt tổng hợp [17].

3.1.2 Huấn luyện mô hình

Hệ thống phân loại tin giả trong nghiên cứu này thực hiện phân tích dữ liệu từ các bài báo nhằm xác định các đặc điểm đặc trưng của tin tức giả và tin tức thật. Quá trình này được tiến hành thông qua việc xử lý văn bản của tiêu đề, nội dung và các yếu tố liên quan để phát hiện các mô thức ngôn ngữ, cấu trúc câu

cũng như mức độ nhất quán trong thông tin. Dựa trên những đặc điểm được trích xuất, mô hình sẽ đưa ra dự đoán về tính xác thực của bài báo, đồng thời phân loại tin tức vào các nhóm phù hợp.

Sau khi hoàn thiện mô hình dự đoán, hệ thống tiến hành đánh giá hiệu suất thông qua các chỉ số đo lường như độ chính xác (Accuracy), F1-score, Recall nhằm kiểm định tính hiệu quả của thuật toán phân loại. Ngoài ra, để trực quan hóa sự khác biệt giữa tin giả và tin thật, nghiên cứu sử dụng biểu đồ WordCloud để hiển thị tần suất xuất hiện của các từ khóa đặc trưng trong loại tin tức giả. Điều này không chỉ giúp làm rõ các đặc điểm ngôn ngữ của tin giả mà còn hỗ trợ việc diễn giải kết quả của mô hình một cách trực quan hơn.



Hình 6. Sơ đồ mô tả toàn bộ quy trình xây dựng mô hình

3.1.3 Chuẩn bị dữ liệu

Bước chuẩn bị dữ liệu đóng vai trò quan trọng trong toàn bộ quá trình xây dựng mô hình dự đoán tin giả. Trước tiên, dữ liệu được thu thập và tổ chức dữ liệu theo định dạng phù hợp để đảm bảo khả năng xử lý hiệu quả trong các bước tiếp theo.

Trong đề tài này, bộ dữ liệu huấn luyện cho mô hình được lưu trữ dưới dạng một DataFrame bao gồm hai thành phần chính: đường link của bài báo (URL) và nhãn phân loại (TYPE). Cột link bài báo chứa đường dẫn trực tiếp đến bài báo trên các trang tin tức, giúp truy xuất thông tin nguồn gốc. Cột “TYPE” biểu diễn nhãn phân loại tin tức gồm “Real” và “Fake”. Do không có một tập dữ liệu chính thống hoàn toàn đáng tin cậy về tin giả, nghiên cứu này áp dụng phương pháp gán nhãn dựa trên nguồn gốc bài báo và đặc điểm nội dung.

Dữ liệu sau khi thu thập sẽ trải qua bước lọc và tiền xử lý, bao gồm loại bỏ các bài báo trùng lặp, kiểm tra tính hợp lệ của đường link, cũng như loại bỏ những bài báo không đủ nội dung hoặc không thuộc phạm vi nghiên cứu. Điều này giúp đảm bảo rằng dữ liệu đầu vào có chất lượng tốt nhất, tránh nhiễu và tối ưu hóa hiệu suất của mô hình trong quá trình huấn luyện.

3.1.4 Tiền xử lý dữ liệu

3.1.4.1 Giới thiệu công cụ hỗ trợ thu thập dữ liệu

a/ Thư viện NewsPlease

NewsPlease là một thư viện mã nguồn mở được thiết kế để thu thập và trích xuất dữ liệu tin tức từ nhiều nguồn khác nhau trên Internet. Với khả năng thu thập nội dung một cách tự động, thư viện này cho phép truy xuất tiêu đề, nội dung bài báo, tác giả, thời gian xuất bản và các thông tin liên quan khác mà không cần phụ thuộc vào API của từng trang báo. Điều này đặc biệt hữu ích trong việc thu thập dữ liệu phục vụ nghiên cứu, xây dựng hệ thống phân tích tin tức hoặc phát triển mô hình học máy trong xử lý ngôn ngữ tự nhiên (NLP).

Quá trình hoạt động của NewsPlease dựa trên cơ chế thu thập dữ liệu từ web (web scraping). Khi được cung cấp danh sách các đường dẫn (URL) của các bài báo, thư viện này sẽ tự động tải nội dung trang web, trích xuất văn bản chính của bài viết và loại bỏ các thành phần không liên quan như quảng cáo hay menu điều hướng. Nhờ khả năng xử lý linh hoạt và chính xác, NewsPlease trở thành một công cụ hữu ích trong việc thu thập

dữ liệu tin tức phục vụ các bài toán NLP, bao gồm phân loại tin tức, trích xuất thông tin và đặc biệt là phát hiện tin giả.

Các tính năng chính của thư viện này bao gồm:

- Tự động thu thập tin tức từ các trang web chỉ bằng URL hoặc từ nguồn RSS.
- Trích xuất thông tin quan trọng như tiêu đề, nội dung, tác giả, ngày xuất bản,...
- Hỗ trợ nhiều định dạng lưu trữ (JSON, CSV, MongoDB, Elasticsearch).
- Loại bỏ quảng cáo và phần thừa để thu được nội dung sạch.

Cách sử dụng cơ bản:

Cài đặt thư viện:

```
pip install news-please
```

Để sử dụng NewsPlease, người dùng có thể dễ dàng cài đặt thư viện thông qua trình quản lý gói của Python. Sau khi cài đặt, một đoạn mã đơn giản có thể được sử dụng để thu thập và trích xuất thông tin từ các bài báo trực tuyến.

Ví dụ, đoạn mã sau minh họa cách sử dụng NewsPlease để thu thập nội dung từ một bài báo cụ thể:

```
from newsplease import NewsPlease

url = "https://vnexpress.net/bo-quoc-phong-tiep-tuc-sap-nhap-mot-so-don-vi-4857294.html"
article = NewsPlease.from_url(url)
print("Tiêu đề:", article.title)
print("Tác giả:", article.authors)
print("Ngày xuất bản:", article.date_publish)
print("Nội dung:", article maintext)
```

Trong nghiên cứu về phân loại tin tức giả, NewsPlease đóng vai trò quan trọng trong việc thu thập dữ liệu từ nhiều nguồn tin tức khác nhau, giúp xây dựng tập dữ liệu phục vụ quá trình huấn luyện mô hình. Nhờ khả năng tự động hóa và thu thập thông tin chính xác, thư viện này giúp tiết kiệm thời gian, đồng thời đảm bảo chất lượng dữ liệu đầu vào cho các thuật toán NLP. Việc kết hợp NewsPlease với các mô hình học sâu như BERT hoặc LSTM có thể giúp tối ưu hóa quy trình phát hiện tin tức giả, đồng thời nâng

cao độ chính xác trong việc phân loại và đánh giá mức độ tin cậy của các bài báo trên Internet.

Về ứng dụng thực tế đối với quá trình thực nghiệm, việc kết hợp NewsPlease với các mô hình học sâu như BERT, LSTM hoặc Transformer có thể giúp tối ưu hóa quy trình phát hiện tin tức giả, đồng thời nâng cao độ chính xác trong việc phân loại và đánh giá mức độ tin cậy của các bài báo trên Internet. Khi dữ liệu được thu thập một cách có hệ thống và chính xác, việc phát triển các mô hình học máy sẽ trở nên hiệu quả hơn, góp phần nâng cao chất lượng của các hệ thống nhận diện tin tức giả trong thực tế.

b/ Thư viện Underthsea

Trong lĩnh vực xử lý ngôn ngữ tự nhiên (NLP), sự phát triển của các công cụ hỗ trợ phân tích văn bản tiếng Việt đóng vai trò quan trọng trong việc nâng cao hiệu quả nghiên cứu và ứng dụng thực tế. Một trong những thư viện tiêu biểu được thiết kế chuyên biệt cho tiếng Việt là Underthsea. Đây là một thư viện mã nguồn mở, cung cấp nhiều công cụ mạnh mẽ để thực hiện các tác vụ xử lý ngôn ngữ như tách từ, gán nhãn từ loại, phân tích cú pháp, dịch máy và trích xuất thực thể có tên. Các tính năng của thư viện này gồm có: Tách từ, loại bỏ Stopwords, gán nhãn từ, nhận diện thực thể có tên, phân tích cú pháp, dịch máy và phân loại văn bản.

Trong nghiên cứu này, nhóm đã sử dụng Underthsea để hỗ trợ quá trình tiền xử lý dữ liệu văn bản, cụ thể là hai tính năng quan trọng: tách từ (word segmentation) và loại bỏ stopwords. Dưới đây là các bước nhóm đã thực hiện:

❖ Tách từ (Word Segmentation):

Trong tiếng Việt, từ ngữ không được phân tách bằng dấu cách như tiếng Anh, do đó việc tách từ là một bước quan trọng trước khi trích xuất đặc trưng hoặc đưa dữ liệu vào mô hình học máy. Nhóm đã sử dụng hàm `word_tokenize()` của Underthsea để chuyển đổi văn bản từ dạng thô sang danh sách các từ riêng lẻ, giúp cải thiện độ chính xác khi xử lý dữ liệu.

Ví dụ, câu:

"Học máy là một lĩnh vực quan trọng trong trí tuệ nhân tạo."

sẽ được tách thành:

"Học máy | là | một | lĩnh vực | quan trọng | trong | trí tuệ nhân tạo |."

❖ Loại bỏ Stopwords

Sau khi tách từ, nhóm tiếp tục thực hiện bước loại bỏ stopwords nhằm giảm thiểu sự xuất hiện của các từ không mang nhiều ý nghĩa (ví dụ: "là", "của", "và", "trong",...). Danh sách stopwords [17] được nhóm tải từ một tệp văn bản và sử dụng để lọc bỏ các từ dư thừa.

Cụ thể, nhóm đã thực hiện:

Trước hết, tải danh sách stopwords từ tệp 'vietnamese-stopwords.txt'. Sau đó áp dụng danh sách này để loại bỏ stopwords khỏi tập dữ liệu. Cuối cùng, lưu kết quả vào một cột mới trong tập dữ liệu, giúp so sánh văn bản trước và sau khi làm sạch.

Câu ban đầu:

"Trong thời đại công nghệ phát triển nhanh chóng, trí tuệ nhân tạo và học máy đang dần trở thành những yếu tố quan trọng, góp phần thay đổi nhiều lĩnh vực trong cuộc sống con người."

Danh sách stopwords chứa các từ như: "trong", "và", "đang", "dần", "trở thành", "những", "nhiều". Khi loại bỏ những từ này, kết quả sẽ là:

Kết quả sau khi loại bỏ stopwords:

"Thời đại | công nghệ | phát triển | nhanh chóng | trí tuệ nhân tạo | học máy | yếu tố | quan trọng | góp phần | thay đổi | lĩnh vực | cuộc sống | con người |."

Như vậy, câu sau khi làm sạch đã giảm bớt các từ không cần thiết nhưng vẫn giữ được ý nghĩa quan trọng, giúp mô hình tập trung vào các từ khóa quan trọng như "học máy", "lĩnh vực", "quan trọng", "trí tuệ nhân tạo" để cải thiện độ chính xác trong phân loại văn bản. Việc áp dụng hai bước tiền xử lý trên giúp chuẩn hóa văn bản, giảm nhiễu và cải thiện hiệu suất của mô hình.

Để cài đặt Underthesea chúng ta sử dụng lệnh:

```
!pip install underthesea
```

Sau khi cài đặt xong, chúng ta import thư viện và sử dụng một số chức năng của nó. Ví dụ, để tách từ trong văn bản tiếng Việt, ta sử dụng đoạn mã sau:

```
from underthesea import word_tokenize
```

Tiếp theo, đoạn mã sẽ lọc stopwords từ danh sách stopwords cơ bản, bao gồm các từ không mang nhiều ý nghĩa. Sau đó, một hàm `remove_stopwords()` được khởi tạo để loại bỏ các từ này khỏi văn bản. Hàm này hoạt động bằng cách trước tiên tách từ bằng `word_tokenize()`, sau đó lọc bỏ các từ xuất hiện trong danh sách stopwords và cuối cùng ghép các từ còn lại thành văn bản sạch.

```
file_path = "/content/drive/MyDrive/Dataset/vietnamese-stopwords.txt"
with open(file_path, "r", encoding="utf-8") as f:
    vietnamese_stop_words = set(f.read().splitlines())
```

```
def remove_stopwords(text):
    words = word_tokenize(text, format="text").split()
    words = [word for word in words if word.lower() not in vietnamese_stop_words]
    return " ".join(words)

df["Text"] = df["Text"].apply(remove_stopwords)
```

Trong đề tài nghiên cứu lần này, Underthesea đóng vai trò quan trọng trong việc tiền xử lý dữ liệu văn bản, giúp chuẩn hóa dữ liệu trước khi đưa vào mô hình học sâu. Cụ thể, thư viện hỗ trợ tách từ chính xác, loại bỏ nhiễu, trích xuất đặc trưng ngôn ngữ và nhận diện thực thể có tên, từ đó giúp cải thiện độ chính xác trong việc phân loại tin tức.

Ví dụ, khi sử dụng Underthesea để chuẩn bị dữ liệu đầu vào cho mô hình BERT, LSTM hoặc CNN, quá trình tiền xử lý sẽ bao gồm tách từ, chuẩn hóa văn bản và loại bỏ các từ không cần thiết. Điều này giúp mô hình dễ dàng học được các đặc trưng quan trọng trong tin tức, đồng thời giảm thiểu ảnh hưởng của dữ liệu nhiễu.

Nhờ vào tính linh hoạt và khả năng tích hợp với nhiều mô hình học sâu, Underthesea đã trở thành một công cụ không thể thiếu trong NLP tiếng Việt, đặc biệt là trong các bài toán như phát hiện tin giả, phân tích cảm xúc và tóm tắt văn bản.

3.1.4.2 Xử lý dữ liệu

Trước tiên, dữ liệu thu thập được từ nhiều nguồn khác nhau có thể chứa nhiễu, lỗi chính tả hoặc định dạng không đồng nhất. Vì vậy, bước đầu tiên nhóm em xử lý dữ liệu văn bản, bao gồm loại bỏ các ký tự đặc biệt, số, dấu câu không cần thiết và chuẩn hóa chữ viết thường để giảm độ phức tạp khi mô hình xử lý.

Sau đó, để giảm bớt các từ không mang nhiều ý nghĩa, các stopwords phổ biến trong tiếng Việt được loại bỏ, nhằm giữ lại những từ quan trọng nhất phản ánh nội dung bài báo. Một số từ mang tính giạt gân có thể được giữ lại để phục vụ mục tiêu nghiên cứu về tin giả.

3.1.4.3 Trích xuất đặc trưng

Để mô hình có thể hiểu và học được từ dữ liệu văn bản, văn bản cần được chuyển đổi thành dạng số. Phương pháp word embedding như TF-IDF, Word2Vec hoặc BERT embedding được sử dụng để mã hóa từ ngữ thành vector số, giúp mô hình nắm bắt được mối quan hệ ngữ nghĩa giữa các từ.

3.1.5 Chia tập dữ liệu, xây dựng mô hình

❖ Cân bằng dữ liệu

Trước khi tiến hành huấn luyện mô hình, một bước quan trọng cần thực hiện là cân bằng dữ liệu nhằm đảm bảo rằng mô hình không bị thiên vị về một lớp cụ thể. Trong đề tài nhóm nghiên cứu, tập dữ liệu thu thập đang bị mất cân bằng do số lượng tin thật và tin giả không đồng đều (231 tin thật và 196 tin giả). Do đó áp dụng phương pháp Random Undersampling để giảm bớt số lượng mẫu thuộc nhóm chiếm ưu thế, giúp mô hình học tốt hơn trên cả hai loại tin tức.

Quy trình thực hiện được tiến hành như sau:

Trước tiên, dữ liệu được chia thành hai phần: đặc trưng đầu vào (X) và nhãn đầu ra (y). Trong đó, cột Text chứa nội dung bài báo được sử dụng làm đặc trưng, trong khi cột Type là nhãn phân loại, xác định bài báo thuộc nhóm tin thật (Type = 1) hay tin giả (Type = 0).

Tiếp theo, kỹ thuật Random Undersampling được áp dụng bằng cách sử dụng thư viện imblearn. Phương pháp này sẽ giảm bớt số lượng mẫu thuộc nhóm chiếm ưu thế, sao cho tổng số lượng bài báo trong cả hai nhóm trở nên cân bằng. Cụ thể, quá trình này được thực hiện bằng cách sử dụng RandomUnderSampler, sau đó gọi phương thức fit_resample(X, y) để tạo ra một tập dữ liệu mới có số lượng tin thật và tin giả đồng đều.

Sau khi cân bằng dữ liệu (đồng đều tin giả và tin thật đều là 196), kết quả được chuyển đổi thành một DataFrame mới (df_balanced) để tiếp tục sử dụng trong quá trình huấn luyện mô hình. Đồng thời, số lượng mẫu của từng nhóm sau khi điều chỉnh được kiểm tra thông qua phương thức value_counts(), nhằm đảm bảo rằng dữ liệu đã được cân bằng một cách hợp lý.

❖ Chia dữ liệu thành tập huấn luyện

Sau khi dữ liệu đã được cân bằng, bước tiếp theo trong quá trình xây dựng mô hình là chia dữ liệu thành tập huấn luyện và tập kiểm tra nhằm đánh giá hiệu quả của mô hình. Dữ liệu được phân chia theo tỷ lệ 80% cho tập huấn luyện và tập kiểm tra là 20%. Cột Text được sử dụng làm đặc trưng đầu vào (X), trong khi cột Type đóng vai trò là nhãn phân loại (y). Để đảm bảo sự cân bằng giữa các lớp trong tập huấn luyện và kiểm tra, tham số `stratify=df["Type"]` được sử dụng, giúp giữ nguyên tỷ lệ giữa các nhãn sau khi chia.

Sau khi chia tách, kết quả kiểm tra cho thấy tập huấn luyện (train) có 313 mẫu và tập kiểm tra (test) có 79 mẫu.

❖ Chuẩn bị các tham số mô hình

Sau khi dữ liệu đã được tiền xử lý và chia thành các tập huấn luyện, kiểm tra, quá trình xây dựng mô hình được tiến hành để huấn luyện hệ thống phân loại tin giả. Trước tiên, cần lựa chọn các tham số phù hợp đối với mỗi mô hình để tối ưu hóa khả năng nhận diện tin giả. Việc lựa chọn mô hình cho bài toán phân loại tin giả này đòi hỏi sự cân nhắc kỹ lưỡng dựa trên đặc điểm dữ liệu và khả năng tổng quát hóa của từng phương pháp. Trong nghiên cứu này, nhóm đã quyết định sử dụng ba mô hình CNN, LSTM và BERT do những lợi thế vượt trội của chúng trong xử lý ngôn ngữ tự nhiên, đặc biệt là đối với tiếng Việt.


Sau khi hoàn thành huấn luyện, mô hình sẽ được đánh giá dựa trên các chỉ số Accuracy, F1-score, Precision và Recall để đo lường hiệu suất. Ngoài ra, kết quả dự đoán cũng được trực quan hóa bằng cách xây dựng Wordcloud, hiển thị các từ đặc trưng xuất hiện nhiều nhất trong tin giả. Điều này giúp nhận diện các từ khóa có xu hướng giật gân hoặc làm quá trong các bài báo không chính thống.

3.2. Huấn luyện mô hình

3.2.1. Mô hình LSTM

Mô hình LSTM được xây dựng dựa trên dữ liệu văn bản đã qua tiền xử lý. Trước tiên, văn bản được chuyển đổi thành chuỗi số thông qua Tokenizer và đảm bảo độ dài đồng nhất bằng kỹ thuật padding. Tiếp theo, mô hình LSTM được thiết kế với lớp nhúng (Embedding) để học biểu diễn từ vựng, lớp LSTM giúp xử lý thông tin chuỗi, và lớp đầu ra với hàm kích hoạt sigmoid để đưa ra xác suất phân loại.

Mô hình được biên dịch với hàm mất mát binary cross-entropy và tối ưu bằng thuật toán Adam. Quá trình huấn luyện diễn ra trong 5 epoch với batch size 32, sử dụng tập kiểm tra để đánh giá hiệu suất.



Hình 7. Ma trận nhầm lẫn mô hình LSTM

Trong ma trận này, hàng đại diện cho nhãn thực tế, cột biểu diễn nhãn dự đoán. Kết quả thu được cho thấy mô hình dự đoán đúng 36 trường hợp tin thật (True Positive) và 31 trường hợp tin giả (True Negative). Tuy nhiên, vẫn tồn tại một số sai sót, với 4 trường hợp tin thật bị nhầm thành tin giả (False Positive) và 8 trường hợp tin giả bị nhầm thành tin thật (False Negative).


Sự chênh lệch giữa các giá trị này phản ánh khả năng phân loại của mô hình. Số lượng False Negative tương đối cao có thể gây ảnh hưởng đến tính chính xác trong việc phát hiện tin giả, cho thấy mô hình vẫn cần được cải thiện, cụ thể, việc cân bằng tập dữ liệu đóng vai trò quan trọng trong việc giảm thiểu hiện tượng mô hình bị thiên lệch về phía nhãn có tần suất cao hơn. Điều này có thể được thực hiện thông qua kỹ thuật oversampling, tức là tăng số lượng mẫu của lớp ít hơn, hoặc undersampling, tức là giảm số lượng mẫu của lớp nhiều hơn, nhằm đảm bảo sự phân bố dữ liệu đồng đều hơn. Bên cạnh đó, quá trình tinh chỉnh siêu tham số cũng có thể giúp tối ưu hóa hiệu suất mô hình.

3.2.2. Mô hình BERT

Trong quá trình nghiên cứu, mô hình BERT đã được lựa chọn để thực hiện bài toán phân loại tin tức thật – giả, nhờ khả năng học ngữ cảnh hiệu quả trong các bài toán

xử lý ngôn ngữ tự nhiên. Quá trình huấn luyện được triển khai trên nền tảng TensorFlow với việc sử dụng mô hình tiền huấn luyện bert-base-uncased từ thư viện transformers. Dữ liệu đầu vào được token hóa bằng *BertTokenizer*, trong đó mỗi câu được chuyển đổi thành một chuỗi token cố định độ dài 128. Sau đó, các dữ liệu đã mã hóa được chuyển đổi thành dạng TensorFlow Dataset để tối ưu hóa quá trình huấn luyện. Mô hình BERT sử dụng *TFBertForSequenceClassification* với hai nhãn đầu ra tương ứng với hai lớp phân loại. Trình tối ưu hóa Adam kết hợp với cơ chế điều chỉnh siêu tham số đã được áp dụng nhằm cải thiện hiệu suất mô hình.

Quá trình huấn luyện được thực hiện trong 3 epoch với kích thước batch là 16. Kết quả cho thấy độ chính xác của mô hình trên tập kiểm tra tăng dần qua từng epoch, đạt 69.62% sau epoch cuối cùng. Báo cáo phân loại cho thấy mô hình có độ chính xác trung bình cao trên cả hai lớp, với điểm F1-score dao động trong khoảng 0.68 – 0.70.



Hình 8. Ma trận nhầm lẫn mô hình BERT

Kết quả trực quan từ ma trận nhầm lẫn cho thấy mô hình BERT hoạt động tương đối tốt nhưng vẫn tồn tại một số lỗi phân loại đáng chú ý. Cụ thể, mô hình đã dự đoán chính xác 29 mẫu thuộc lớp 0 (tin thật) và 32 mẫu thuộc lớp 1 (tin giả). Tuy nhiên, có 11 trường hợp thuộc lớp 0 bị dự đoán nhầm thành lớp 1 và 7 trường hợp thuộc lớp 1 bị phân loại nhầm thành lớp 0. Điều này cho thấy mô hình có xu hướng nhầm lẫn khi phân loại tin thật thành tin giả nhiều hơn so với chiều ngược lại. Nguyên nhân có thể xuất phát từ sự tương đồng về mặt ngữ nghĩa giữa các tin tức trong tập dữ liệu, dẫn đến việc mô hình gặp khó khăn trong việc xác định ranh giới chính xác giữa hai loại tin. Việc


tính chỉnh mô hình hoặc sử dụng các kỹ thuật tiền xử lý dữ liệu nâng cao có thể giúp cải thiện hiệu suất phân loại.

3.2.3. Mô hình CNN

Mô hình mạng nơ-ron tích chập (CNN) được sử dụng để phân loại tin tức dựa trên nội dung văn bản ở nghiên cứu này. Việc huấn luyện mô hình trải qua các bước chính, bao gồm tiền xử lý dữ liệu, xây dựng kiến trúc mô hình, tối ưu hóa và đánh giá hiệu suất.

Ban đầu, dữ liệu văn bản được mã hóa thành các chuỗi số nguyên bằng cách sử dụng Tokenizer, với số lượng từ tối đa là 10.000 và độ dài câu tối đa là 200. Sau đó, các chuỗi số này được xử lý bằng kỹ thuật padding để đảm bảo tất cả các mẫu có cùng độ dài, giúp tối ưu hóa quá trình huấn luyện.

Mô hình CNN được thiết kế với một lớp nhúng (Embedding) nhằm chuyển đổi từ ngữ thành dạng vector có ý nghĩa trong không gian đặc trưng. Tiếp theo, các lớp tích chập (Conv1D) với kích thước cửa sổ khác nhau được sử dụng để trích xuất các đặc trưng quan trọng từ văn bản. Sau mỗi lớp tích chập là một lớp MaxPooling giúp giảm chiều dữ liệu và giữ lại các đặc trưng nổi bật nhất. Mô hình cũng áp dụng các lớp Dropout để tránh hiện tượng quá khớp, cùng với lớp Dense ở đầu ra để thực hiện phân loại nhị phân.



Hình 9. Ma trận nhầm lẫn mô hình CNN

Mô hình được huấn luyện bằng thuật toán tối ưu Adam với hàm mất mát `binary_crossentropy`, do bài toán thuộc dạng phân loại hai lớp. Sau quá trình huấn luyện,

mô hình đạt được độ chính xác nhất định trên tập kiểm tra. Kết quả đánh giá được thể hiện thông qua báo cáo phân loại, trong đó cung cấp các chỉ số quan trọng như độ chính xác (accuracy), độ nhạy (recall) và độ đo F1-score.

Ma trận nhầm lẫn của mô hình CNN cho thấy khả năng phân loại tương đối chính xác, với phần lớn các mẫu được dự đoán đúng. Cụ thể, mô hình đã nhận diện đúng 34 mẫu thuộc lớp 0 (tin thật) và 32 mẫu thuộc lớp 1 (tin giả). Tuy nhiên, vẫn còn một số sai sót khi 6 mẫu tin thật bị nhầm lẫn thành tin giả và 7 mẫu tin giả bị phân loại sai thành tin thật.

Nhìn chung, so với mô hình LSTM và BERT, CNN thể hiện độ chính xác cao trong việc nhận diện tin thật, song vẫn gặp thách thức trong việc phân biệt tin giả. Điều này có thể do sự tương đồng về mặt ngôn ngữ giữa hai loại tin tức hoặc mô hình chưa khai thác triệt để các đặc trưng ngữ nghĩa phức tạp. Để nâng cao hiệu suất, có thể xem xét tối ưu hóa siêu tham số, cải thiện kỹ thuật tiền xử lý dữ liệu hoặc kết hợp với các mô hình ngôn ngữ tiên tiến hơn nhằm tăng cường khả năng phân loại.

3.3. Đánh giá mô hình

Hiệu suất của các mô hình được đánh giá thông qua các chỉ số:

- Accuracy (Độ chính xác): Tỷ lệ dự đoán đúng trên tổng số mẫu.
- Precision (Độ chính xác theo lớp): Đánh giá tỷ lệ dự đoán đúng trong tổng số dự đoán dương tính.
- Recall (Độ nhạy): Đánh giá khả năng nhận diện đúng các mẫu thuộc lớp dương tính.
- F1-score: Trung bình điều hòa giữa Precision và Recall, giúp cân bằng giữa hai yếu tố này.

Những chỉ số này đảm bảo việc đánh giá mô hình được thực hiện toàn diện, phản ánh chính xác hiệu suất trên tập kiểm tra.

❖ Mô hình LSTM

Mô hình LSTM được huấn luyện trên tập dữ liệu với 5 epoch, sử dụng hàm mất mát binary cross-entropy và bộ tối ưu hóa Adam. Trong quá trình huấn luyện, độ chính xác trên tập huấn luyện có xu hướng tăng dần, trong khi độ chính xác trên tập kiểm tra dao động và đạt mức cao nhất ở epoch cuối cùng.

1. Hiệu suất huấn luyện và kiểm tra

Mô hình LSTM đã được huấn luyện trong 5 epoch với độ chính xác trên tập huấn luyện tăng dần từ 54.18% ở epoch đầu tiên lên 96.77% ở epoch cuối cùng. Đồng thời, độ chính xác trên tập kiểm tra (validation accuracy) cũng có sự cải thiện từ 69.23% lên 83.33%. Giá trị loss giảm đáng kể từ 0.6924 xuống còn 0.2542, cho thấy mô hình có khả năng học hiệu quả từ dữ liệu huấn luyện.

Mặc dù độ chính xác trên tập kiểm tra đạt mức cao, nhưng khoảng cách lớn giữa accuracy của tập huấn luyện (96.77%) và tập kiểm tra (83.33%) cho thấy mô hình có dấu hiệu overfitting nhẹ.

2. Đánh giá chi tiết trên tập kiểm tra

Sau khi huấn luyện, mô hình được đánh giá trên tập kiểm tra bằng cách sử dụng độ chính xác, báo cáo phân loại và các chỉ số đánh giá khác.

Trên tập kiểm tra, mô hình đạt độ chính xác (accuracy) 83.33%. Khi xét các chỉ số chi tiết, độ đo precision của lớp 0 (negative class) đạt 76%, recall lên đến 97%, và F1-score là 85%. Trong khi đó, lớp 1 có precision cao hơn (96%) nhưng recall thấp hơn (69%), dẫn đến F1-score là 81%. Điều này phản ánh rằng mô hình có xu hướng nhận diện tốt lớp 0 nhưng vẫn bỏ sót một số trường hợp thuộc lớp 1.

3. Phân tích kết quả

Mô hình đạt độ chính xác khá cao với precision và recall tương đương, cho thấy không bị thiên lệch giữa các lớp. Tuy nhiên, độ chính xác trên tập huấn luyện cao hơn so với tập kiểm tra, phản ánh dấu hiệu overfitting, làm giảm khả năng tổng quát hóa trên dữ liệu thực tế. Chỉ số recall thấp của lớp 1 cho thấy mô hình, chứng tỏ mô hình vẫn cần cải thiện để đạt kết quả tốt hơn.

4. Đề xuất cải thiện

Để giảm overfitting, có thể tăng dropout, áp dụng regularization (L1, L2) hoặc mở rộng dữ liệu huấn luyện. Ngoài ra, thử nghiệm mô hình BiLSTM, GRU hoặc tăng số epoch có thể giúp nâng cao độ chính xác, nhưng cần theo dõi để tránh overfitting nghiêm trọng hơn.

Nhận xét:

Mô hình đạt độ chính xác 83.33% trên tập kiểm tra, thấp hơn so với 96.77% trên tập huấn luyện, cho thấy hiện tượng overfitting. Điều này có thể xuất phát từ việc mô hình chưa được điều chỉnh tối ưu hoặc tập dữ liệu huấn luyện chưa đủ đa dạng. Precision và recall giữa hai lớp có sự chênh lệch, đặc biệt recall của lớp tin giả chỉ đạt 0.69, cho thấy

mô hình chưa phân loại tốt các trường hợp này. Giá trị F1-score trung bình đạt 0.83, tương đối tốt nhưng vẫn có thể cải thiện. Để nâng cao hiệu suất, có thể tăng dropout, thử nghiệm mô hình BiLSTM hoặc áp dụng kỹ thuật điều chỉnh dữ liệu để cân bằng giữa hai lớp.

❖ Mô hình BERT

1. Hiệu suất huấn luyện và kiểm tra

Mô hình BERT đã được huấn luyện và đánh giá trên tập kiểm tra, đạt độ chính xác tổng thể là 79.49%. Với thời gian dự đoán trung bình khoảng 44 giây mỗi bước, mô hình thể hiện khả năng xử lý hiệu quả trên tập dữ liệu kiểm tra. Kết quả này cho thấy BERT có khả năng học biểu diễn ngữ nghĩa tốt từ văn bản, nhưng vẫn tồn tại sai số nhất định trong phân loại.

2. Đánh giá chi tiết trên tập kiểm tra

Trên tập kiểm tra, mô hình đạt precision trung bình 81%, recall 79% và F1-score 79%. Khi xét riêng từng lớp, lớp 0 có precision cao (87%) nhưng recall chỉ đạt 69%, dẫn đến F1-score là 77%. Ngược lại, lớp 1 có precision thấp hơn (74%) nhưng recall đạt 90%, tạo ra F1-score 79%. Điều này phản ánh rằng mô hình có xu hướng phân loại chính xác hơn đối với lớp 1 (tin thật), trong khi gặp khó khăn hơn khi nhận diện lớp 0 (tin giả).

3. Phân tích kết quả

Kết quả phân loại của BERT cho thấy một xu hướng quan trọng: mô hình có độ nhạy cao đối với lớp tin thật nhưng dễ bỏ sót các tin giả, thể hiện qua recall thấp của lớp 0. Điều này có thể do các mẫu tin giả trong tập dữ liệu có cấu trúc ngữ nghĩa phức tạp hoặc tương đồng với tin thật, khiến mô hình khó phân biệt chính xác. Precision cao của lớp 0 nhưng recall thấp cũng gợi ý rằng mô hình có thể đang phân loại tin giả một cách thận trọng, dẫn đến tỷ lệ bỏ sót cao hơn.

4. Đề xuất cải thiện

Để nâng cao hiệu suất mô hình, có thể áp dụng một số phương pháp cải tiến như tăng cường dữ liệu (data augmentation) nhằm tạo ra các mẫu tin giả đa dạng hơn, giúp mô hình học được các đặc trưng rõ ràng hơn. Ngoài ra, có thể thử nghiệm tinh chỉnh BERT (fine-tuning) với các siêu tham số khác nhau hoặc sử dụng các phiên bản nâng cao như RoBERTa hoặc DeBERTa để cải thiện khả năng phân loại.

❖ Mô hình CNN

1. Hiệu suất huấn luyện và kiểm tra

Mô hình CNN đã được huấn luyện với 5 epoch, trong đó độ chính xác trên tập huấn luyện tăng dần từ 50.83% lên 95.04%, trong khi độ chính xác trên tập kiểm tra đạt 93.59% ở epoch cuối cùng. Đồng thời, giá trị mất mát giảm đáng kể từ 0.6969 xuống còn 0.2367 trên tập huấn luyện và từ 0.6913 xuống 0.2451 trên tập kiểm tra. Những kết quả này cho thấy mô hình đã học được biểu diễn tốt qua quá trình huấn luyện và có khả năng tổng quát hóa tốt trên tập kiểm tra.

2. Đánh giá chi tiết trên tập kiểm tra

Khi đánh giá trên tập kiểm tra, mô hình CNN đạt độ chính xác 87%, cao hơn so với Trên tập kiểm tra, mô hình đạt độ chính xác tổng thể 93.59%, với precision và recall trung bình đều ở mức 94%, dẫn đến F1-score đạt 94%. Khi xét riêng từng lớp, lớp 0 có precision và recall đều là 94%, trong khi lớp 1 cũng đạt các giá trị tương tự. Điều này phản ánh khả năng phân loại chính xác và cân bằng giữa hai lớp của mô hình CNN.

3. Phân tích kết quả

Kết quả phân loại cho thấy mô hình CNN có hiệu suất cao, không chỉ đạt độ chính xác ấn tượng mà còn duy trì sự cân bằng giữa precision và recall. Điều này cho thấy mô hình có khả năng nhận diện chính xác cả hai loại tin tức mà không thiên vị một lớp nào. Hơn nữa, với độ chính xác gần 94%, mô hình đã chứng minh được tính hiệu quả trong việc trích xuất các đặc trưng từ văn bản bằng các tầng tích chập. Tuy nhiên, mặc dù hiệu suất cao, vẫn cần xem xét khả năng mô hình có thể đã bị overfitting khi hiệu suất trên tập huấn luyện gần như đạt mức tuyệt đối.

4. Đề xuất cải thiện

Để đảm bảo mô hình hoạt động ổn định hơn trên các tập dữ liệu chưa thấy, có thể áp dụng một số phương pháp điều chỉnh như sử dụng dropout với tỷ lệ cao hơn hoặc áp dụng kỹ thuật regularization nhằm giảm nguy cơ overfitting. Ngoài ra, có thể thử nghiệm với các kiến trúc CNN sâu hơn hoặc kết hợp với các mô hình khác như LSTM hoặc Transformer để tận dụng tốt hơn thông tin ngữ cảnh trong văn bản. Việc đánh giá mô hình trên các tập dữ liệu đa dạng hơn cũng là một hướng quan trọng nhằm kiểm chứng khả năng tổng quát hóa trong các bối cảnh thực tế.

❖ Ma trận nhầm lẫn (Confusion Matrix)

Ma trận nhầm lẫn (Confusion Matrix) là một công cụ quan trọng trong lĩnh vực học máy, đặc biệt là đối với các bài toán phân loại. Đây là một phương pháp trực quan hóa giúp đánh giá hiệu suất của mô hình bằng cách so sánh kết quả dự đoán với nhãn thực

tế. Thay vì chỉ sử dụng độ chính xác tổng thể (accuracy), ma trận nhầm lẫn cung cấp một cái nhìn chi tiết hơn về cách mô hình xử lý từng lớp dữ liệu, qua đó hỗ trợ phân tích điểm mạnh và điểm yếu của thuật toán phân loại.

Trong bài toán phân loại nhị phân, ma trận nhầm lẫn có dạng một bảng 2×2 , trong đó các ô thể hiện số lượng dự đoán đúng hoặc sai của mô hình:

	Dự đoán là 0	Dự đoán là 1
Thực tế là 0	True Negative (TN)	False Positive (FP)
Thực tế là 1	False Negative (FN)	True Positive (TP)

Bảng 3. Mô tả về ma trận nhầm lẫn

Các phần tử trong ma trận có ý nghĩa như sau:

- True Positive (TP): Số lượng mẫu thuộc lớp 1 được dự đoán chính xác.
- True Negative (TN): Số lượng mẫu thuộc lớp 0 được dự đoán chính xác.
- False Positive (FP): Số lượng mẫu thuộc lớp 0 nhưng bị dự đoán nhầm thành lớp 1 (hay còn gọi là lỗi loại I).
- False Negative (FN): Số lượng mẫu thuộc lớp 1 nhưng bị dự đoán nhầm thành lớp 0 (hay còn gọi là lỗi loại II).

Việc phân tích ma trận nhầm lẫn giúp xác định liệu mô hình có xu hướng mắc lỗi nào nhiều hơn, từ đó điều chỉnh thuật toán để cải thiện hiệu suất.

Dựa trên các giá trị trong ma trận nhầm lẫn, một số chỉ số quan trọng thường được sử dụng để đánh giá mô hình phân loại bao gồm:

❖ Độ chính xác (Accuracy)

$$Accuracy = \frac{TP + TN}{TP + TN + FP + FN}$$

❖ Độ nhạy (Recall)

$$Recall = \frac{TP}{TP + FN}$$

❖ Độ đặc hiệu (Specificity)

$$Specificity = \frac{TN}{TN + FP}$$

❖ Độ chính xác của mô hình với lớp dương (Precision)

$$Precision = \frac{TP}{TP + FP}$$

❖ F1-Score

$$F1 = 2 * \frac{Precision * Recall}{Precision + Recall}$$

Trong nghiên cứu này, ma trận nhầm lẫn được sử dụng để đánh giá hiệu suất của các mô hình học máy và học sâu trong nhiệm vụ phân loại tin giả. Một ma trận nhầm lẫn tối ưu sẽ có số lượng TP và TN cao, đồng thời giảm thiểu FP và FN. Nếu mô hình có tỷ lệ FP cao, điều đó có nghĩa là nhiều tin thật bị nhầm lẫn thành tin giả, gây ra tác động tiêu cực đối với các nền tảng thông tin. Ngược lại, nếu FN cao, nhiều tin giả có thể bị bỏ sót, làm giảm tính hiệu quả của hệ thống phát hiện tin giả.

Dựa trên phân tích ma trận nhầm lẫn, các chiến lược có thể được áp dụng để cải thiện hiệu suất mô hình, chẳng hạn như điều chỉnh trọng số lớp, sử dụng các thuật toán cân bằng dữ liệu (SMOTE) hoặc điều chỉnh ngưỡng phân loại (threshold tuning).

Để trực quan hóa và đánh giá hiệu suất mô hình, thư viện sklearn.metrics hỗ trợ tính toán ma trận nhầm lẫn và các chỉ số đánh giá liên quan.

```
import numpy as np
import matplotlib.pyplot as plt
import seaborn as sns
from sklearn.metrics import confusion_matrix, classification_report

# Ví dụ nhãn thực tế và nhãn dự đoán
y_true = np.array([1, 0, 1, 1, 0, 1, 0, 0, 1, 0]) # Nhãn thực tế
y_pred = np.array([1, 0, 1, 0, 0, 1, 1, 0, 1, 0]) # Nhãn dự đoán

# Tính toán ma trận nhầm lẫn
cm = confusion_matrix(y_true, y_pred)

# Hiển thị ma trận nhầm lẫn
plt.figure(figsize=(6, 4))
sns.heatmap(cm, annot=True, fmt="d", cmap="Blues", xticklabels=["Dự đoán 0",
"Dự đoán 1"],
            yticklabels=["Thực tế 0", "Thực tế 1"])
```

```
plt.xlabel("Giá trị Dự đoán")
plt.ylabel("Giá trị Thực tế")
plt.title("Ma Trận Nhầm Lẫn")
plt.show()

# In báo cáo
print("Báo cáo phân loại:\n", classification_report(y_true, y_pred))
```

Trong đề tài nghiên cứu, việc sử dụng ma trận nhầm lẫn giúp đánh giá sự cân bằng giữa Precision và Recall, đảm bảo rằng mô hình không bỏ sót các tin giả quan trọng cũng như không tạo ra quá nhiều cảnh báo sai đối với tin thật. Những phân tích này là cơ sở quan trọng để lựa chọn mô hình tối ưu, từ đó nâng cao hiệu quả của hệ thống phát hiện tin tức sai lệch.

3.4. Kết quả thực nghiệm và phân tích kết quả

3.4.1. Công cụ thực nghiệm

Trong nghiên cứu này, Google Colab được sử dụng làm nền tảng để huấn luyện và đánh giá các mô hình phân loại tin giả, đảm bảo hiệu suất tính toán cao và khả năng xử lý dữ liệu lớn mà không bị giới hạn bởi tài nguyên phần cứng cá nhân. Với ưu điểm hỗ trợ ngôn ngữ Python cùng hệ sinh thái thư viện phong phú, Google Colab cho phép xử lý dữ liệu hiệu quả và triển khai các mô hình học máy một cách thuận tiện.

Cụ thể, thư viện *pandas* và *numpy* được dùng để thao tác, xử lý và tính toán dữ liệu nhanh chóng, thư viện *matplotlib* và *seaborn* hỗ trợ trực quan hóa kết quả ma trận, giúp việc phân tích trở nên trực quan và dễ hiểu hơn. Đặc biệt, *wordcloud* được sử dụng để trực quan hóa tần suất xuất hiện của các từ khóa quan trọng, giúp phát hiện các đặc điểm ngôn ngữ đặc trưng trong tin giả và tin thật. Trong xử lý ngôn ngữ tự nhiên, *underthesea* đóng vai trò quan trọng trong việc tách từ, gán nhãn từ loại và chuẩn hóa văn bản tiếng Việt, giúp cải thiện chất lượng dữ liệu đầu vào. Bên cạnh đó, *sklearn* cung cấp các công cụ hữu ích như trích xuất đặc trưng TF-IDF, chia tập dữ liệu, huấn luyện mô hình và đánh giá kết quả thông qua các chỉ số quan trọng như accuracy, precision, recall và F1-score.

Đối với các mô hình học sâu, *tensorflow* và *torch* được sử dụng để xây dựng và huấn luyện các kiến trúc như LSTM, CNN và BERT, tận dụng GPU trên Google Colab để tăng tốc quá trình huấn luyện.

3.4.2 Hiệu suất mô hình trên tập kiểm tra

Mô hình	Precision	Recall	F1-score	Accuracy
LSTM	96%	69%	81%	83%
BERT	74%	90%	81%	80%
CNN	93%	95%	94%	94%

Bảng 4. So sánh hiệu suất của ba mô hình

Trong quá trình chạy thực nghiệm, ba mô hình LSTM, BERT và CNN đã được triển khai và đánh giá dựa trên các chỉ số Precision, Recall, F1-score và Accuracy. Kết quả cho thấy CNN hoạt động ổn định và hiệu quả nhất với độ chính xác vượt trội so với hai mô hình còn lại.

Cụ thể, mô hình CNN đạt Accuracy 94%, cao hơn đáng kể so với LSTM (83%) và BERT (80%). Điều này cho thấy mô hình này có khả năng tổng quát hóa tốt hơn, phân loại tin tức một cách chính xác và đáng tin cậy. Ngoài ra, CNN cũng sở hữu F1-score cao nhất (94%), thể hiện sự hài hòa giữa Precision (93%) và Recall (95%). Đặc biệt, Recall của CNN cao nhất trong ba mô hình, cho thấy khả năng phát hiện tin tức khá tốt, hạn chế tối đa tình trạng bỏ sót thông tin sai lệch.

LSTM nổi bật với Precision cao nhất (96%), phản ánh khả năng xác định chính xác tin giả khi mô hình đưa ra dự đoán dương tính. Tuy nhiên, Recall chỉ đạt 69%, tức là mô hình có xu hướng bỏ sót nhiều tin giả, làm giảm hiệu suất tổng thể. F1-score của LSTM đạt (81%), thấp hơn rõ rệt so với CNN, cho thấy sự mất cân bằng giữa độ chính xác khi nhận diện và khả năng bao quát dữ liệu.

BERT, trong khi đó, có Recall tương đối cao (90%), nhỉnh hơn LSTM và chỉ đứng sau CNN. Điều này thể hiện khả năng phát hiện tin giả của mô hình là khá tốt. Tuy nhiên, Precision chỉ đạt 74%, thấp hơn đáng kể so với hai mô hình còn lại, dẫn đến tỷ lệ dự đoán sai cao hơn. Đây cũng là nguyên nhân khiến Accuracy của BERT chỉ đạt (80%) thấp nhất trong ba mô hình.

Tổng quan, ta có thể thấy CNN là lựa chọn tối ưu khi vừa đạt độ chính xác cao nhất vừa đảm bảo sự cân bằng giữa Precision và Recall. LSTM có độ chính xác cao khi dự đoán nhưng lại dễ bỏ sót tin giả, trong khi BERT nhận diện được nhiều tin giả hơn nhưng lại

gặp vấn đề với Precision. Kết quả này khẳng định CNN là mô hình phù hợp nhất để ứng dụng vào bài toán phân loại tin tức trong nghiên cứu của nhóm.

Mô hình	Training time (s)	Testing time (s)	F-measure Average
LSTM	19.426	1.24	0.83
BERT	1451	44	0.79
CNN	15	0.069	0.94

Bảng 5. So sánh thời gian chạy trên ba mô hình

Dựa trên kết quả thực nghiệm, có thể thấy rõ sự khác biệt về hiệu suất giữa ba mô hình LSTM, BERT và CNN trong bài toán phân loại.

CNN cho thấy ưu thế vượt trội khi vừa có độ chính xác cao nhất (F-measure đạt 0.94), vừa có thời gian huấn luyện (15 giây) và kiểm tra (0.069 giây) ngắn nhất. Điều này chứng tỏ mô hình không chỉ hoạt động hiệu quả mà còn tiết kiệm đáng kể tài nguyên tính toán.

Trong khi đó, LSTM có thời gian huấn luyện chỉ nhỉnh hơn CNN một chút (19.426 giây) nhưng lại mất nhiều thời gian hơn để kiểm tra (1.24 giây). Mặc dù vậy, F-measure của LSTM vẫn đạt 0.83, cao hơn BERT, cho thấy mô hình này có thể là một lựa chọn tốt nếu cân bằng giữa độ chính xác và thời gian kiểm tra.

BERT, mặc dù được biết đến với khả năng xử lý ngôn ngữ mạnh mẽ, nhưng lại tốn khá nhiều thời gian để huấn luyện và 44 giây để kiểm tra—cao hơn rất nhiều so với hai mô hình còn lại. Đáng chú ý, hiệu suất của BERT (F-measure 0.79) lại không cao như mong đợi, thậm chí thấp hơn cả LSTM. Điều này đặt ra câu hỏi về việc liệu có thực sự cần thiết sử dụng một mô hình phức tạp như BERT cho bài toán này, khi mà CNN vẫn đạt độ chính xác cao hơn với chi phí tính toán thấp hơn đáng kể.

3.4.3. Kết quả trực quan dữ liệu – WordCloud

Trong nghiên cứu này, nhóm đã áp dụng phương pháp Word Cloud nhằm trực quan hóa tần suất xuất hiện của các từ giật gân trong các bài báo không chính thống. Việc sử dụng Word Cloud giúp cung cấp cái nhìn trực quan về mức độ phổ biến của các từ trong tập dữ liệu, từ đó hỗ trợ quá trình phân tích đặc trưng ngôn ngữ của tin tức sai lệch.

Để đảm bảo tính chính xác và hiệu quả trong quá trình trực quan hóa, nhóm tiến hành tiền xử lý dữ liệu theo một quy trình chặt chẽ. Trước tiên, văn bản được chuẩn hóa

bằng cách chuyển đổi toàn bộ nội dung về chữ thường nhằm tránh sự phân biệt giữa các dạng viết hoa và viết thường. Tiếp theo, nhóm thực hiện loại bỏ dấu câu, ký tự đặc biệt và các thành phần không mang ý nghĩa ngữ nghĩa như dấu gạch ngang, ngoặc kép hoặc các ký tự không thuộc bảng chữ cái. Sau đó, phương pháp tokenization được áp dụng để tách văn bản thành các từ riêng lẻ, hỗ trợ quá trình phân tích ngữ nghĩa và thống kê tần suất xuất hiện của từng từ.

Một bước quan trọng trong quá trình xử lý dữ liệu là loại bỏ các từ dừng (stopwords). Các từ dừng bao gồm những từ có tần suất xuất hiện cao nhưng ít mang giá trị thông tin, chẳng hạn như "là", "của", "và", "nhưng", "hoặc". Nhóm đã sử dụng danh sách stopwords tiếng Việt phổ biến [17]. Việc loại bỏ stopwords giúp đảm bảo rằng chỉ những từ mang tính đặc trưng nhất được giữ lại để đưa vào quá trình phân tích.

Sau khi hoàn tất quá trình tiền xử lý, nhóm áp dụng phương pháp TF-IDF (Term Frequency - Inverse Document Frequency) nhằm xác định các từ khóa có mức độ quan trọng cao trong tập dữ liệu. Phương pháp này giúp đo lường mức độ quan trọng của từng từ trong mối quan hệ với toàn bộ tập dữ liệu, từ đó làm nổi bật các từ có tính phân biệt cao giữa các loại văn bản. Những từ có trọng số TF-IDF cao nhất được lựa chọn và đối chiếu với danh sách từ giật gân đã được thu thập từ các nghiên cứu trước đó. Bước này đảm bảo rằng chỉ các từ mang tính đặc trưng cao của tin tức không chính thống mới được sử dụng trong mô hình trực quan hóa.

Sau khi hoàn tất quá trình chọn lọc, nhóm tổng hợp danh sách từ sau khi lọc thành một chuỗi văn bản duy nhất để làm đầu vào cho mô hình Word Cloud. Nhóm sử dụng thư viện wordcloud trong Python để tạo hình ảnh trực quan, trong đó kích thước của mỗi từ phản ánh tần suất xuất hiện của nó trong tập dữ liệu. Các từ xuất hiện với tần suất cao sẽ có kích thước lớn hơn, giúp dễ dàng nhận diện các xu hướng ngôn ngữ phổ biến trong các bài báo không chính thống.

Kết quả WordCloud phản ánh rõ nét xu hướng ngôn ngữ trong tập dữ liệu, với sự nổi bật của các từ mang sắc thái mạnh, chủ yếu tập trung vào những nội dung gây tranh cãi, giật gân hoặc mang sắc thái kích thích cảm xúc mạnh và khuynh hướng thu hút sự chú ý của độc giả.

Những từ như "*tranh cãi*", "*căng thẳng*", "*xôn xao*", hay "*khủng khiếp*" xuất hiện với tần suất cao, cho thấy văn bản trong tập dữ liệu có thể liên quan đến các chủ đề nóng, dễ thu hút sự chú ý và tạo ra phản ứng mạnh từ công chúng.



Hình 10. Kết quả thể hiện trực quan các từ xuất hiện nhiều

Sự xuất hiện nổi bật của những từ ngữ này phản ánh đặc trưng ngôn ngữ của các bài viết không chính thống, trong đó việc sử dụng những thuật ngữ có tính cường điệu nhằm tạo hiệu ứng mạnh mẽ về mặt cảm xúc là một chiến lược phổ biến để thu hút người đọc. Ngược lại, trong các bài viết chính thống, các từ mang tính trung lập hoặc có mức độ giật gân thấp hơn có xu hướng chiếm ưu thế. Do đó, việc phát hiện và phân tích các từ có trọng số TF-IDF cao không chỉ giúp làm rõ sự khác biệt về mặt ngôn ngữ giữa tin giả và tin thật mà còn có thể hỗ trợ xây dựng các mô hình phân loại tin tức dựa trên đặc trưng văn bản một cách hiệu quả.

Đáng chú ý, sự xuất hiện thường xuyên của các từ chỉ số lượng lớn như "hàng trăm", "triệu", gợi ý về xu hướng nhấn mạnh quy mô sự kiện, điều thường thấy trong các bài viết mang tính giật tít hoặc kích thích cảm xúc. Điều này có thể ảnh hưởng đến nhận thức của độc giả và tiềm ẩn nguy cơ tạo ra hiệu ứng lan truyền mạnh mẽ, dù chưa rõ mức độ xác thực của thông tin. Từ đây, có thể đặt ra giả thuyết về mối liên hệ giữa cách lựa chọn ngôn từ và bản chất của tin tức trong tập dữ liệu. Nếu nội dung có xu hướng sử dụng từ ngữ mạnh để thu hút sự chú ý, liệu điều đó có đồng nghĩa với việc thông tin được thể hiện một cách khách quan? Kết quả này mở ra hướng nghiên cứu quan trọng về vai trò của ngôn ngữ trong việc tác động đến niềm tin và cảm xúc của công chúng, đặc biệt trong nghiên cứu phân loại tin tức.

Từ kết quả phân tích trên, ta có thể thấy rằng tin giả có xu hướng sử dụng ngôn ngữ kích động, nhấn mạnh các yếu tố tiêu cực hoặc gây tranh cãi để thu hút sự chú ý. Điều này mở ra nhiều hướng nghiên cứu ứng dụng trong lĩnh vực xử lý ngôn ngữ tự nhiên (NLP), đặc biệt là trong việc phát triển các mô hình phát hiện tin giả tự động. Kết quả cũng đặt ra câu hỏi về ảnh hưởng của ngôn ngữ trong việc định hướng dư luận. Nếu các bài viết dù thật hay giả đều có xu hướng sử dụng từ ngữ cường điệu, liệu điều này

có làm thay đổi cách công chúng tiếp nhận thông tin? Điều đó gợi ý một hướng nghiên cứu sâu hơn về tác động của ngôn ngữ đối với nhận thức và hành vi của người đọc, đồng thời nhấn mạnh tầm quan trọng của việc phát triển các mô hình phân loại không chỉ dựa vào nội dung mà còn xét đến phong cách diễn đạt.

Việc kết hợp TF-IDF với các mô hình học máy có thể giúp cải thiện độ chính xác của hệ thống phân loại tin tức bằng cách tập trung vào những từ có giá trị phân biệt cao, thay vì chỉ dựa vào tần suất thô. Đồng thời, các mô hình có thể được mở rộng bằng cách kết hợp thêm các đặc trưng ngữ nghĩa hoặc mô hình học sâu như BiLSTM, Transformer để tăng cường khả năng nhận diện các mẫu ngôn ngữ phức tạp hơn.

CHƯƠNG 4 : KẾT LUẬN VÀ HƯỚNG PHÁT TRIỂN

4.1 Kết luận

Đề tài nghiên cứu của nhóm bằng học sâu vẫn đối mặt với nhiều thách thức. Một trong những khó khăn lớn nhất là sự thay đổi không ngừng của tin giả, đòi hỏi mô hình phải được cập nhật thường xuyên để duy trì hiệu quả. Ngoài ra, việc thu thập và gán nhãn tập dữ liệu cân bằng vẫn là một trở ngại lớn, ảnh hưởng trực tiếp đến chất lượng huấn luyện mô hình. Hơn nữa, hầu hết các mô hình hiện tại chỉ dựa vào nội dung văn bản, mà chưa khai thác đầy đủ các yếu tố ngữ cảnh như nguồn tin, quan hệ giữa các bài viết hoặc tác động xã hội. Điều này đặt ra nhu cầu phát triển các hướng nghiên cứu mới nhằm cải thiện độ chính xác và khả năng ứng dụng thực tế của mô hình phát hiện tin giả.

Tuy nhiên, so với các nghiên cứu trước đây, mô hình học sâu trong nghiên cứu này vẫn cho thấy hiệu quả vượt trội. Các nghiên cứu trước chủ yếu dựa vào học máy truyền thống như Naive Bayes và SVM. Cụ thể, nghiên cứu [7] sử dụng hai mô hình này để phát hiện tin giả, trong đó SVM có độ chính xác cao hơn Naive Bayes nhưng vẫn chưa thể cạnh tranh với các phương pháp học sâu. Xu hướng nghiên cứu gần đây đã dần chuyển dịch sang deep learning nhờ vào hiệu suất vượt trội của các mô hình này. Chẳng hạn, nghiên cứu [9] so sánh giữa học máy truyền thống (SVM, Naive Bayes) và học sâu (CNN, RNN), kết quả cho thấy CNN và RNN có độ chính xác cao hơn. Tương tự, nghiên cứu [15] thử nghiệm LSTM, Bi-LSTM và CNN-BiLSTM trong việc phát hiện tin giả tiếng Việt, trong đó CNN-BiLSTM đạt hiệu suất tốt nhất.

So với các phương pháp trên, mô hình CNN trong nghiên cứu hiện tại đạt độ chính xác cao hơn đáng kể (~93.59%), tiếp tục khẳng định ưu thế của học sâu trong bài toán này. Tuy nhiên, để nâng cao hiệu suất và khả năng ứng dụng thực tế, có thể áp dụng các phương pháp như tăng cường dữ liệu (data augmentation), sử dụng mô hình ngôn ngữ tiên tiến hơn như PhoBERT – phiên bản BERT tối ưu hóa cho tiếng Việt, hoặc kết hợp nhiều mô hình khác nhau để khai thác thế mạnh của từng phương pháp. Ngoài ra, tích hợp thông tin từ nhiều nguồn và sử dụng học tăng cường (reinforcement learning) có thể giúp mô hình thích nghi tốt hơn với các dạng tin giả mới, vốn liên tục thay đổi để đánh lừa hệ thống phát hiện.

4.2 Hạn chế của nghiên cứu

Mặc dù nghiên cứu đã đạt được những kết quả đáng chú ý trong việc so sánh hiệu suất của các mô hình CNN, LSTM và BERT trong bài toán phân loại tin giả, nhưng vẫn tồn tại một số hạn chế cần được xem xét.

Trước hết, dữ liệu huấn luyện có thể chưa đủ đa dạng để mô hình học được tất cả các đặc trưng của tin giả trên thực tế. Do giới hạn về nguồn dữ liệu, tập huấn luyện có thể chứa những mẫu văn bản chưa thực sự phản ánh hết sự phức tạp của tin giả trong môi trường thực tế, đặc biệt là các tin tức có yếu tố ẩn ý hoặc sử dụng lối hành văn tinh vi nhằm đánh lừa người đọc. Điều này có thể khiến mô hình hoạt động chưa thực sự tối ưu khi áp dụng vào dữ liệu mới, làm giảm khả năng tổng quát hóa.

Thứ hai, mặc dù BERT là một mô hình ngôn ngữ tiên tiến, nhưng hiệu suất chưa cao có thể xuất phát từ việc mô hình chưa được tinh chỉnh đầy đủ hoặc chưa tận dụng hết tiềm năng của kiến trúc Transformer. Việc huấn luyện BERT đòi hỏi nhiều tài nguyên tính toán hơn so với LSTM hay CNN, điều này có thể đã ảnh hưởng đến khả năng tối ưu hóa trong phạm vi nghiên cứu này. Do đó, một hướng nghiên cứu quan trọng là tối ưu hóa mô hình, giảm thiểu chi phí tính toán mà vẫn duy trì hiệu suất cao, chẳng hạn như sử dụng các mô hình nhẹ hơn hoặc áp dụng các kỹ thuật nén mô hình.

Ngoài ra, nghiên cứu chủ yếu tập trung vào ba mô hình học sâu phổ biến mà chưa mở rộng sang các kỹ thuật tiên tiến hơn như ensemble learning hoặc các biến thể mới của Transformer như RoBERTa hay DeBERTa. Việc thử nghiệm thêm các mô hình này có thể mang lại những cải tiến đáng kể về hiệu suất.

Cuối cùng, việc đánh giá hiệu suất chỉ dừng lại ở các chỉ số định lượng như Accuracy, Precision, Recall và F1-score. Trong thực tế, tin giả thường có nhiều dạng khác nhau, từ tiêu đề gây hiểu lầm cho đến nội dung hoàn toàn sai sự thật. Một phân tích định tính sâu hơn về cách mô hình xử lý từng loại tin giả khác nhau có thể giúp hiểu rõ hơn về điểm mạnh và điểm yếu của từng phương pháp.

Những hạn chế này mở ra nhiều hướng nghiên cứu trong tương lai, bao gồm việc mở rộng tập dữ liệu, cải thiện phương pháp tiền xử lý văn bản, tối ưu hóa mô hình và áp dụng các kỹ thuật nâng cao để nâng cao độ chính xác và khả năng tổng quát hóa của hệ thống.

4.3 Đề xuất hướng nghiên cứu trong tương lai

Một trong những hướng phát triển nhóm muốn thực hiện là *xây dựng một bộ từ điển các từ ngữ giật gân*, dạng nội dung tinh vi hoặc ngữ cảnh đặc biệt như tin tức mang tính chất giật gân, thông tin sai lệch có chủ đích và các bài viết mang yếu tố gây hiểu lầm thường xuất hiện trong các bài viết giả mạo. Việc này giúp mô hình có thể nhận diện các đặc điểm ngôn ngữ đặc trưng của tin giả và từ đó tăng độ chính xác trong việc phân loại. Đồng thời, việc mở rộng tập dữ liệu từ nhiều nguồn khác nhau, bao gồm báo chí chính thống, mạng xã hội và diễn đàn trực tuyến, sẽ giúp mô hình học được nhiều dạng thức biểu đạt của tin tức. Bên cạnh đó, dữ liệu cũng cần được làm sạch và chuẩn hóa để giảm thiểu các yếu tố gây nhiễu, chẳng hạn như lỗi chính tả, từ viết tắt hay nội dung trùng lặp. Một hướng đi tiềm năng là phát triển tập dữ liệu đa ngôn ngữ nhằm tăng cường khả năng tổng quát hóa của mô hình, giúp nó có thể hoạt động tốt trong nhiều bối cảnh khác nhau.

Về phương diện mô hình học máy và học sâu, việc tối ưu hóa các mô hình hiện tại và *kết hợp nhiều mô hình khác nhau* có thể mang lại kết quả khả quan hơn. Chẳng hạn, việc sử dụng mô hình BERT để trích xuất đặc trưng văn bản, sau đó áp dụng SVM để phân loại, có thể giúp khai thác hiệu quả khả năng biểu diễn ngữ nghĩa của BERT và tính chính xác cao của SVM. Tương tự, LSTM kết hợp với Attention Mechanism có thể giúp mô hình tập trung vào các từ khóa quan trọng trong câu, cải thiện hiệu suất dự đoán. Ngoài ra, các mô hình tiên tiến hơn như RoBERTa, T5 hay GPT-4 cũng cần được nghiên cứu và so sánh để đánh giá mức độ hiệu quả trong bối cảnh phát hiện tin giả.

Để nâng cao hiệu suất và tính khả dụng của mô hình, có thể áp dụng các phương pháp như tăng cường dữ liệu (data augmentation), *sử dụng mô hình ngôn ngữ tiên tiến hơn như PhoBERT – một phiên bản BERT được tối ưu hóa cho tiếng Việt*, hoặc kết hợp nhiều mô hình khác nhau để khai thác thế mạnh của từng phương pháp. Ngoài ra, tích hợp thông tin từ nhiều nguồn và sử dụng học tăng cường (reinforcement learning) có thể giúp mô hình thích nghi tốt hơn với các dạng tin giả mới, vốn liên tục thay đổi để đánh lừa hệ thống phát hiện.

Bên cạnh việc cải thiện mô hình, việc *tích hợp AI vào các ứng dụng thực tế* là một bước tiến quan trọng nhằm hỗ trợ người dùng phát hiện và kiểm chứng tin tức nhanh chóng. Một số ứng dụng tiềm năng bao gồm chatbot AI có khả năng phân tích và xác minh tin tức trên các nền tảng mạng xã hội, tiện ích mở rộng trên trình duyệt web giúp

kiểm tra độ tin cậy của nội dung khi người dùng truy cập trang báo, hoặc hệ thống đánh giá nguồn tin dựa trên mức độ uy tín của tác giả và trang báo. Những công cụ này không chỉ giúp người dùng tiếp cận thông tin chính xác hơn mà còn góp phần hạn chế sự lan truyền của tin giả trên không gian mạng.

TÀI LIỆU THAM KHẢO

- [1]. Danh, B. C., & Hiền, N. T. D. (2023). MỘT SỐ PHƯƠNG PHÁP PHÁT HIỆN TIN TỨC GIẢ MẠO TRONG NGÔN NGỮ TIẾNG VIỆT. Tạp chí Khoa học, 20(6), 980.
- [2]. Reddy, H., Raj, N., Gala, M., & Basava, A. (2020). Text-mining-based fake news detection using ensemble methods. International Journal of Automation and Computing, 17(2), 210-221.
- [3]. Hieu, T. N., Minh, H. C. N., Van, H. T., & Quoc, B. V. (2020, December). ReINTEL Challenge 2020: Vietnamese Fake News Detection using Ensemble Model with PhoBERT embeddings. In Proceedings of the 7th international workshop on Vietnamese language and speech processing (pp. 1-5).
- [4]. Hùng, V. T., Chi, N. K., & Kiệt, T. A. (2022). Phát hiện tự động tin giả: Thành tựu và thách thức. Tạp chí Khoa học và Công nghệ-Đại học Đà Nẵng, 71-78.
- [5]. Phương, N. T. K., & Thiện, P. T. Phát hiện tin giả dựa trên nội dung và ngữ cảnh xã hội sử dụng học máy.
- [6]. Asha, J., & Meenakowshalya, A. (2021). Fake news detection using n-gram analysis and machine learning algorithms. Journal of Mobile Computing, Communications & Mobile Networks, 8(1), 33-43p.
- [7]. Nagaraja, A., KN, S., Sinha, A., RAJENDRA KUMAR, J. V., & Nayak, P. (2021, April). Fake news detection using machine learning methods. In International Conference on Data Science, E-learning and Information Systems 2021 (pp. 185-192).
- [8]. Manzoor, S. I., & Singla, J. (2019, April). Fake news detection using machine learning approaches: A systematic review. In 2019 3rd international conference on trends in electronics and informatics (ICOEI) (pp. 230-234). IEEE.
- [9]. Han, W., & Mehta, V. (2019, November). Fake news detection in social networks using machine learning and deep learning: Performance evaluation. In 2019 IEEE international conference on industrial internet (ICII) (pp. 375-380). IEEE.
- [10]. D2L AI Việt Nam, “LSTM – Mạng nơ-ron hồi tiếp dài ngắn hạn,” 2024.

- [11]. S. Huber, "Convolutional Neural Networks and Their Applications in NLP," *LMU Munich NLP Seminar*, 2020.
- [12]. T. Q. Định và P. T. T. Kiều, "Nghiên cứu giải pháp phát hiện tin giả trên mạng xã hội bằng ngôn ngữ tiếng Việt," *Tạp chí Nghiên cứu Kinh tế và Kinh doanh Châu Á*, vol. 33, no. 5, pp. 26-46, 2022.
- [13]. D. Jurafsky and J. H. Martin, *Speech and Language Processing*, 3rd ed.
- [14]. Pandey, S., Prabhakaran, S., Reddy, N. S., & Acharya, D. (2022). Fake news detection from online media using machine learning classifiers. In *Journal of Physics: Conference Series* (Vol. 2161, No. 1, p. 012027). IOP Publishing.
- [15]. Vo, D. V., & Do, P. (2023). Detecting Vietnamese fake news. *CTU Journal of Innovation and Sustainable Development*, 15(Special issue: ISDS), 39-46.
- [16]. Ahmed, H., Traore, I., & Saad, S. (2017). Detection of online fake news using n-gram analysis and machine learning techniques. In *Intelligent, Secure, and Dependable Systems in Distributed and Cloud Environments: First International Conference, ISDDC 2017, Vancouver, BC, Canada, October 26-28, 2017, Proceedings 1* (pp. 127-138). Springer International Publishing.
- [17]. Stopwords - <https://github.com/stopwords/vietnamese-stopwords>.